Probabilité et Statistique

Dr Malicki ZOROM

Cours de Probabilité et Statistique de S4 et S6D

"*Département Science et Techniques de l'Ingénieur*"

email: malicki.zorom@2ie-edu.org

Institut 2iE

23 février 2026

Plan

1. Probabilité
2. Variables aléatoires
3. Lois usuelles
4. Statistique descriptive
5. Échantillonnage et estimation

Plan

1. Probabilité
2. Variables aléatoires
3. Lois usuelles
4. Statistique descriptive
5. Échantillonnage et estimation

Plan

1. Probabilité
2. Variables aléatoires
3. Lois usuelles
4. Statistique descriptive
5. Échantillonnage et estimation

Plan

1. Probabilité
2. Variables aléatoires
3. Lois usuelles
4. Statistique descriptive
5. Échantillonnage et estimation

Plan

1. Probabilité
2. Variables aléatoires
3. Lois usuelles
4. Statistique descriptive
5. Échantillonnage et estimation

Plan

6 Tests d'hypothèses

Plan

1. Probabilité
   - Rappel sur les dénombrements
   - Probabilité
   - Probabilité conditionnelle
     - Loi uniforme discrète
     - Loi Bernoulli
     - Loi Binomiale
     - Loi Géométrique
     - Loi Hypergéométrique
     - Loi de Poisson
     - Approximations de loi discrète
     - Loi uniforme continue
     - Loi exponentielle
     - Loi Normale
     - Approximation de la loi binomiale par la loi normale
     - Théorèmes limites

Arrangements et permutations

Envisageons un ensemble de n objets différents. Choisissons maintenant r de ces n objets et ordonnons les.

Définition

Une disposition ordonnée de r objets distincts pris parmi n est appelée *arrangement* de r objets pris parmi n (on a obligatoirement $r \leq n$).

Combien y en a-t-il ?
Pour compter le nombre total d'arrangements de r objets pris parmi n, il suffit de considérer les r positions comme fixées et de compter le nombre de façons dont on peut choisir les objets pour les placer dans ces r positions. C'est une expérience à r étapes où l'on applique la technique du paragraphe précédent. Pour la première position, on a n choix possibles. Pour la deuxième position, on a $n-1$ choix possibles... Pour la r-ième position, on a $n-r+1$ choix possibles. Si on désigne par A_n^r le nombre total d'arrangements cherchés, l'arbre aura A_n^r branches terminales. On conclut $A_n^r = n(n-1)(n-2)\cdots(n-r+1) = \frac{n!}{(n-r)!}$.

rappel

$n!$ (lire "factorielle n") est le produit de tous les entiers jusqu'à n, $n! = n(n-1)(n-2)\cdots 3.2.1$. Par convention, $0! = 1$.

Exemple : Les arrangements de deux lettres prises parmi 4 lettres $\{a, b, c, d\}$ sont au nombre de $A_4^2 = \frac{4!}{2!} = 12$. Ce sont : $(a,b), (a,c), (a,d), (b,a), (b,c), (b,d), (c,a), (c,b), (c,d), (d,a), (d,b), (d,c)$.
Cas particulier : $r = n$ Il s'agit d'ordonner n objets entre eux, c'est-à-dire d'effectuer une permutation de ces n objets.

Définition

Une permutation de n éléments est une disposition ordonnée de ces n éléments.

Les permutations de n éléments sont au nombre de $A_n^n = n!$.

Combinaisons

Définition

Un choix de r objets distincts pris parmi n sans tenir compte de leur ordre est appelé combinaison de r objets pris parmi n.

Dans l'exemple précédent correspondant à l'ensemble des quatre lettres $\{a, b, c, d\}$, la combinaison $\{a, b\}$ est la même que la combinaison $\{b, a\}$ alors que l'arrangement (a, b) est différent de l'arrangement (b, a).
Combien y en a-t-il ? Le nombre total de combinaisons de r objets pris parmi n est noté C_n^r . Pour trouver l'expression de C_n^r, comparons le nombre d'arrangements et de combinaisons possibles de r objets pris parmi n.

- Dans un arrangement on choisit r objets, puis on tient compte de leur ordre.
- Dans une combinaison seul le choix des r objets compte. Comme le nombre de façons d'ordonner les r objets choisis est $r!$, on conclut qu'à chaque combinaison de r objets pris parmi n, on peut associer $r!$ arrangements et donc qu'il y a $r!$ fois plus d'arrangements que de combinaisons.

On conclut

Proposition

$$C_n^r = \frac{A_n^r}{r!} = \frac{n(n-1)(n-2)\cdots(n-r+1)}{r!} = \frac{n!}{r!(n-r)!}.$$

Exemple

Le nombre de combinaisons de deux lettres prises parmi quatre $\{a, b, c, d\}$ est $C_4^2 = \frac{4!}{2!2!} = 6$. Ce sont :
$\{a, b\}, \{a, c\}, \{a, d\}, \{b, c\}, \{b, d\}, \{c, d\}$.

Exemples

Exemple

Déterminer le nombre de numéros possibles que peuvent attribuer les compagnies téléphoniques au Burkina Faso ?

Exemple

Dans un lot de 20 pièces fabriquées, 4 sont mauvaises. De combien de façon différentes peut-on en prélever 4 dans les cas suivants :

1. les 4 pièces sont bonnes
2. Une au moins d'entre elles est mauvaise.
3. Deux au moins sont mauvaises.

Les réponses dépendent de l'expérience. D'après l'énoncé il n'y a pas répétition mais est-ce que l'ordre compte ? Tirages successifs, arrangements, ou tirage simultané, combinaison ?

Exemple

Une classe de 30 élèves, 12 filles et 18 garçons, doit élire un comité composé d'un président, un vice-président et un secrétaire.

1. Combien de comités peut-on constituer ?
2. Combien de comités peut-on constituer sachant que le poste de secrétaire doit être occupé par une fille ?
3. Quel est le nombre de comités comprenant l'élève X ?
4. Quel est le nombre de comités pour lesquels le président est un garçon et le secrétaire une fille ?
5. Quel est le nombre de comités pour lesquels le président et le vice-président sont de sexes différents ?

Plan

1. Probabilité
   - Rappel sur les dénombrements
   - Probabilité
   - Probabilité conditionnelle
     - Loi uniforme discrète
     - Loi Bernoulli
     - Loi Binomiale
     - Loi Géométrique
     - Loi Hypergéométrique
     - Loi de Poisson
     - Approximations de loi discrète
     - Loi uniforme continue
     - Loi exponentielle
     - Loi Normale
     - Approximation de la loi binomiale par la loi normale
     - Théorèmes limites

Notions de base : Quelques définitions

Théorie des probabilités

- Décrit le comportement de phénomènes dont le résultat est soumis au hasard
- permet de modéliser la fréquence de réalisation d' "évènements " aléatoires

Définitions

- **Expérience aléatoire** ε : expérience dont le résultat ne peut pas être déterminé avec certitude a priori.
- **Univers de** ε : ensemble des aléatoires résultats possibles de ε. On le note Ω.
- **Résultat élémentaire de** ε : résultat possible de ε. C'est un élément de Ω. On le note ω.

Exemples

1. ε : "lancer d'un dé régulier"
   $\Omega = \{1, 2, 3, 4, 5, 6\}$.
   $\omega = 2$ est un résultat possible.
2. ε : "jet de deux pièces de monnaie distinguables"
   $\Omega = \{(P, P), (P, F), (F, P), (F, F)\}$.
   $\omega = (P, P)$ est un résultat possible.
3. ε : "lancer d'un crayon sur une feuille de papier de dimension $l \star L$. Chaque point de la feuille est repéré par son abscisse et son ordonnée"
   $\Omega = \{(x, y), x \in [0, l], y \in [0, L]\}$ est ensemble infini
   $\omega = (\frac{l}{2}, \frac{L}{2})$ est un résultat possible.

Notions de base : évènements

Définitions

- **Ensemble $\mathcal{P}(\Omega)$ des parties de Ω :** ensemble constitué de tous les sous-ensembles (parties) de Ω.
- **Evènement (aléatoire)** =une partie (sous-ensemble) de Ω= assertion, qui peut ou non se réaliser suivant l'issue de ε
- **Réalisation d'un événement** Soit A un évènement de Ω. Soit ω le résultat de l'expérience
  A se réalise $\Longleftrightarrow \omega \in A$

  Cas particulier
  - $A = \Omega$ se réalise toujours. On l'appelle **évènement certain**.
  - $A = \emptyset$ ne se réalise jamais. On l'appelle **évènement impossible**.
  - $A = \{\omega\}$ s'appelle **événement élémentaire**.

Exemples

1. Si $\Omega = \{a, b, c\}$, $\mathcal{P}(\Omega)$ a 8 éléments.
   l'ensemble vide : $\emptyset$
   les parties à un élément : $\{a\}, \{b\}, \{c\}$
   les parties à deux élts. : $\{b, c\}, \{a, c\}, \{a, b\}$
   les parties à trois éléments : $\{a, b, c\} = \Omega$
2. A=" le lancer est pair "$=\{2, 4, 6\}$.
3. A= ń on obtient deux piles ż$=\{(P, P)\}$
   Si le résultat de ε est $\omega = (F, P)$ alors A ne se réalise pas.
4. A="le lancer a une abscisse>l/2 "$=]l/2, l] \star [0, L]$

Opérations sur les évènements

- **Complémentaire de** A : événement constitué des résultats élémentaires de Ω qui ne sont pas dans A. Soit ω le résultat de l'expérience :
  $\overline{A} = \{\omega \in \Omega, \omega \notin A\}$
  $\overline{A}$ se réalise si et seulement si A ne se réalise pas : non A



- **Réunion de** A **et** B : évènement constitué des résultats élémentaires de Ω qui appartiennent à A **ou** à B (ou aux deux). Soit ω le résultat de l'expérience :
  $A \cup B = \{\omega \in \Omega, \omega \in A \text{ ou } \omega \in B\}$
  $A \cup B$ se réalise si et seulement si A se réalise ou B se réalise : A ou B



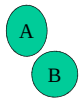
- **Intersection de** A **et** B : évènement constitué des résultats élémentaires de Ω qui appartiennent à la fois à A **et** à B. Soit ω le résultat de l'expérience :
  $A \cap B = \{\omega \in \Omega, \omega \in A \text{ et } \omega \in B\}$
  $A \cap B$ se réalise si et seulement si A et B se réalisent : A et B



- **Inclusion** : A est inclus dans B si et seulement si tout élément de A appartient à B :
  $A \subset B \iff (\omega \in A \implies \omega \in B)$
  Si A est réalisé alors B est réalisé



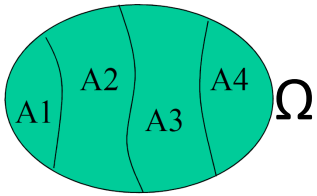
- **Disjonction ou incompatibilité** : A et B sont disjoints si et seulement si A et B n'ont pas d'éléments communs :
  A et B disjoints $\iff \quad A \cap B = \emptyset$
  A et B disjoints : A et B sont incompatibles



Notions de base : évènements

Système complet d'évènements :
Soient $A_1, A_2, \cdots, A_n$ n évènements. On dit que $(A_1, A_2, \cdots, A_n)$ constitue un système complet d'évènements si les **parties** $A_1, A_2, \ldots, A_n$ de Ω constituent une **partition** de Ω telle que :

- ils sont deux à deux incompatibles i.e. $\forall i,\ A_i \neq \emptyset, \forall i \neq j,\ A_i \cap A_j = \emptyset$
- si leur réunion est l'événement certain Ω i.e. $\bigcup_{i=1}^{n} A_i = \Omega$



Exemple : $(A, \overline{A})$ forme un système complet d'évènements.

Notions de base : évènements

Tribu d'évènements de Ω, espace probabilisable

- Tribu d'un ensemble de parties de Ω : Soit $\mathcal{A} \in \mathcal{P}(\Omega)$. $\mathcal{A}$ est une **tribu** ou **sigma-algèbre** si elle contient Ω et est stable par complémentation et réunion dénombrable. On dit alors que $(\Omega, \mathcal{A})$ est un **espace probabilisable**.
  Exemples :
  Tribu grossière $\mathcal{A} = \{\emptyset, \Omega\}$
  Tribu des parties (appelée aussi tribu discrète) $\mathcal{A} = \mathcal{P}(\Omega)$
  Tribu des boréliens $A = \{]a, +\infty[,\ a \in \mathbb{Q}\ (ou\ \mathbb{R})\}$, lorsque $\Omega = \mathbb{R}$
  Tribu $\mathcal{A} = \{A, \overline{A}, \emptyset, \Omega\}$
  Tribu $\Omega = \{a, b, c, d\}$ $\mathcal{A} = \{\emptyset, \{a\}, \{b, c, d\}, \Omega\}$
- **Choix d'une tribu** : se fait en fonction de l'information qu'on a sur le problème. lorsque l'univers est fini ou dénombrable, on travaille généralement avec la tribu discrète. Lorsque l'univers est infini ($\Omega = \mathbb{R}$ ou I un intervalle de $\mathbb{R}$) on travaille avec la tribu borélienne.

Notions de base : probabilité

Probabilité= fonction permettant de " mesurer" la chance de réalisation d'un évènement de $\mathcal{P}(\Omega)$ (ou plus généralement d'une tribu $\mathcal{A}$).
Définition : Soit $(\Omega, \mathcal{A})$ un espace probabilisable. Une probabilité sur $(\Omega, \mathcal{A})$ est une application $P : \mathcal{A} \to [0, 1]$ satisfaisant les 3 axiomes suivants :

- $0 \leq P(A) \leq 1, \ \forall A \in \mathcal{A}$
- $P(\Omega) = 1$
- $P(\bigcup_{i \in \mathbb{N}} A_i) = \sum_{i \in \mathbb{N}} P(A_i)$, $\forall (A_i)_{i \in \mathbb{N}}$ ensemble dénombrable d'évènements disjoints

Dès lors que P est définie, $(\Omega, \mathcal{A}, P)$ s'appelle un **espace probabilisé**.

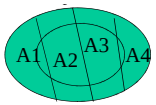
Notions de base : probabilité

Opérations sur les probabilité

- $P(\emptyset) = 0$
- $P(\overline{A}) = 1 - P(A)$ (L'application de cette propriété est très utile lorsque le nombre d'évènements élémentaires de A, k, est important et que le calcul des probabilités p_i est fastidieux.)
- $P(A) \leq P(B)$ si $A \subset B$
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- $P(\bigcup A_i) \leq \sum P(A_i)$
- $0 \leq P(A_i) \leq 1$
- En particulier Si $P(A) = 0$ alors A est *presque impossible*. On écrit $A = \emptyset$ *p.s.*
  Si $P(A) = 1$ alors A est *presque sûr*. On écrit $A = \Omega$ *p.s.*

Axiome des probabilités totales : Soit $(A_i)_{1 \leq i \leq n}$ un système complet d'évènements :

$$\forall B \in \mathcal{A}, P(B) = \sum_{i=1}^{n} P(B \cap A_i) = \sum_{i=1}^{n} P(B/A_i)P(A_i)$$



Notions de base : probabilité

Construction pratique d'une probabilité en univers fini ou dénombrable
On suppose que l'ensemble des événements possibles est fini ou dénombrable. On note $\Omega = \{\omega_1, \cdots, \omega_n, \cdots\}$ l'ensemble des résultats possibles.

- on définit la probabilité p_i de chaque résultat élémentaire ω_i on a alors une suite $(p_1, \cdots, p_n, \cdots)$ de nombres tels que : $0 \leq p_i \leq 1$ et $\sum_{i=1}^{n} p_i = 1$.
- la probabilité d'un événement quelconque A est donné par : $P(A) = \sum_{\omega_i \in A} p_i$.
- **Cas particulier d'un univers fini équiprobable** : Lorsqu'il n'y a pas lieu d'attacher aux différents évènements élémentaires des probabilités différentes, on a pour tout ω, $pi = p$. On dit que l'univers est **équiprobable**. Lorsque l'univers est fini, de cardinal $|\Omega| = card(\Omega)$, on a $p_i = p = \frac{1}{|\Omega|}$.On définit alors la probabilité P comme précédemment : soit A un événement quelconque.

$$P(A) = \frac{|A|}{|\Omega|} = \frac{cardA}{card\Omega} = \frac{\texttt{nombre de cas favorables}}{\texttt{nombre de cas possibles}}$$

Cette probabilité est appelée **probabilité uniforme sur** Ω.
Cette formule permet de ramener les calculs de probabilités à des décomptes d'évènements élémentaires effectués par des techniques d'analyse combinatoire qui ne sont pas des probabilités

Notions de base : probabilité

Exemple 1

ε : "jet de deux pièces de monnaie distinguables". $\Omega = \{(P,P);(P,F);(F,P);(F,F)\}$ est équiprobable. Soit A= "On obtient au moins une fois P"=$\{(P,P);(P,F);(F,P)\}$. $P(A) = 3/4$

Exemple 2

ε : "jet d'un dé pipé : le 6 apparaît 2 fois plus que les autres ". Ω non équiprobable :
$p_1 = p_2 = p_3 = p_4 = p_5 = p; p_6 = 2p$, p tel que :$5p + 2p = 1$, $p = 1/7$
A="le lancer est pair"; $P(A) = p_2 + p_4 + p_6 = 4/7$.

Exemple 3

ε : "lancer de la mine de crayon ". Soit A un événement (surface sur la feuille) de Ω d'aire A. Si tous les emplacements sur la feuille ont la même chance d'être atteints, intuitivement, on peut définir $P(A) = \dfrac{A}{l \star L}$.
Par contre, P((x,y)=0 (lorsque Ω est infini, on admet que la probabilité de tomber sur un point particulier est nulle).

Plan

1. Probabilité
   - Rappel sur les dénombrements
   - Probabilité
   - Probabilité conditionnelle
     - Loi uniforme discrète
     - Loi Bernoulli
     - Loi Binomiale
     - Loi Géométrique
     - Loi Hypergéométrique
     - Loi de Poisson
     - Approximations de loi discrète
     - Loi uniforme continue
     - Loi exponentielle
     - Loi Normale
     - Approximation de la loi binomiale par la loi normale
     - Théorèmes limites

Notions de base : probabilité conditionnelle, indépendance

Définition : Probabilité conditionnelle

Soient deux évènements A et B d'un espace probabilisé Ω avec $P(B) \neq 0$, on appelle probabilité conditionnelle de l'évènement " A si B " (ou " A sachant B "), le quotient

$P(A/B) = \dfrac{P(A \cap B)}{P(B)}$ notée aussi $P_B(A)$

Définition : Indépendance

Deux évènements A et B sont indépendants si $\dfrac{P(A \cap B)}{P(B)} = P(A)$ ou $P(A/B) = P(A)$ ou $P(B/A) = P(B)$

Définition : Généralisation de l'indépendance à n évènements

n évènements $(n \geq 2)$, $A_1, A_2, \ldots, A_i, \ldots, A_n$ sont dit indépendants dans leur ensemble (ou mutuellement indépendants) si on a :

$P(A_1 \cap A_2 \cap \ldots \cap A_i \cap \ldots A_n) = P(A_1) \times P(A_2) \times \ldots \times P(A_i) \times \ldots \times P(A_n)$ ou

$P(\bigcap_{i}^{n} A_i) = \prod_{i=1}^{n} P(A_i)$

Notions de base : probabilité conditionnelle, indépendance

Théorème de Bayes

- Pour deux évènements A et B : $P(A/B) = \dfrac{P(B/A)P(A)}{P(B)}$
- **Généralisation** : Si $\{A_1, A_2, \ldots, A_i, \cdots, A_n\}$ st un système complet d'évènements, et quel que soit l'évènement B tel que $P(B) \neq 0$,

  alors : $P(A_i/B) = \dfrac{P(B/A_i)P(A_i)}{\sum_{i=1}^{n} P(B/A_i)P(A_i)}$ avec

$$P(B) = \sum_{i=1}^{n} P(B/A_i)P(A_i)$$

Exemple : probabilité, probabilité conditionnelle, indépendance

Exemple 1

La probabilité lors du lancer d'un dé non pipé d'obtenir " plus de 2 " se traduit par $A = \{3, 4, 5, 6\}$ et $\overline{A} = \{1, 2\}$ d'où $P(A) = 1 - P(\overline{A}) = 1 - 2/6 = 4/6 = 2/3$

Exemple 2

- Considérons le jeu qui consiste à lancer un dé à 6 faces, non pipé. Soient les deux évènements : A " le résultat est pair " et B " le résultat est un multiple de trois " sont statistiquement indépendants.
  En effet, soit $A = \{2, 4, 6\}$; $B = \{3, 6\}$; $A \cap B = \{6\}$ainsi P(A) =3/6 ; P(B) = 2/6 ; $P(A \cap B) = 1/6$. On vérifie alors que : $P(A \cap B) = P(A)P(B) = 3/6 \times 2/6 = 6/36 = 1/6$
- Si l'on considère une famille de deux enfants, les deux évènements : A " enfants de sexe différent " et B " au plus une fille " ne sont pas statistiquement indépendants. En effet, l'espace probabilisé Ω, contient 4 évènements élémentaires (si l'on considère une famille ordonnée),$\Omega = \{GG, GF, FG, FF\}$ avec $A = \{GF, FG\}$, $B = \{GG, GF, FG\}$ et $A \cap B = \{GF, FG\}$
  d'où sous l'hypothèse d'équiprobabilité : $P(A) = 1/2$, $P(B) = 3/4$ et $P(A \cap B) = 1/2$. On vérifie alors que : $P(A \cap B) \neq P(A)P(B) = 1/2 \times 3/4 = 3/8 \neq 1/2$

Exemple 3

Une population animale comporte 1/3 de mâles et 2/3 de femelles. L'albinisme frappe 6 % des mâles et 0,36 % des femelles. La probabilité pour qu'un individu pris au hasard (dont on ignore le sexe) soit albinos est :
Soient les évènements A :" l'animale est *mâle* " et $\overline{A}$:" l'animale est *femelle*" constitue un système complet d'évènements B :" l'animale est albinos" et $\overline{B}$:" l'animale n'est pas albinos" sachant que $P(B) = P(B/A)P(A) + P(B/\overline{A})P(\overline{A})$ alors $P(B) = (0,06 \times 1/3) + (0,0036 \times 2/3) = 0,0224$ soit 2,24% d'albinos dans cette population.

Exemple : probabilité, probabilité conditionnelle, indépendance

Exemple 4

Dans une population pour laquelle 1 habitant sur 100 est atteint d'une maladie génétique A, on a mis au point un test de dépistage. Le résultat du test est soit positif (T) soit négatif $(\overline{T})$.
On sait que : $P(T/A) = 0,8$ et $P(\overline{T}/\overline{A}) = 0,9$
On soumet un patient au test. Celui-ci est positif. Quelle est la probabilité que ce patient soit atteint de la maladie A soit $P_T(A)$ ou $P(A/T)$?

D'après la formule de Bayes :

$$P(A/T) = \frac{P(T/A)P(A)}{P(T/A)P(A) + P(T/\overline{A})P(\overline{A})}$$

d'où $P(A/T) = \dfrac{0,01 \times 0,8}{0,01 \times 0,8 + 0,1 \times 0,99} = 0,075$

Ainsi avant le test, la probabilité d'être malade était de P(A)=0,01 (probabilité a priori) et après le test la probabilité d'être malade est de $P(A/T) = 0,075$ (probabilité a posteriori). Ainsi le test apporte un supplément d'information.

Dans la plupart des phénomènes aléatoires, le résultat d'une épreuve peut se traduire par une " grandeur " mathématique, très souvent représentée par un nombre entier ou un nombre réel. La notion mathématique qui représente efficacement ce genre de situation concrète est celle de variable aléatoire (notée également v.a.). On se limitera ici au cas des variables aléatoires réelles.

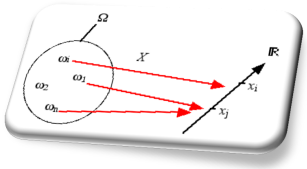
Définition

On suppose une expérience dont l'univers est muni d'une tribu $\mathcal{A}$ d'évènements et d'une probabilité P ($(\Omega, \mathcal{A}, P)$ espace probabilisé) . Une variable aléatoire réelle X est une caractère quantitatif, discret ou continu, dont la valeur est fonction du résultat de l'expérience :

$$X : \Omega \to E$$

$$\omega \mapsto X(\omega) = x$$

(E est l'ensemble des valeurs possibles de X)
qui est mesurable, c'est à dire telle que l'image réciproque $X^{-1}(B) = \{\omega \in \Omega, X(\omega) \in B\}$ de tout élément B de la tribu $\mathcal{B}$ associée à E est un événement de $\mathcal{A}$.
Remarque notation : $\forall B \in \mathcal{B}, X^{-1}(B) \in \mathcal{A}$ et $X^{-1}(B) = \{X \in B\}$ alors, on peut attribuer une chance de réalisation à tout élément B de $\mathcal{B}$



Remarque

- La mesurabilité de X dépend des tribus $\mathcal{A}$ et $\mathcal{B}$ choisie sur Ω et E. La tribu $\mathcal{B}$ est généralement $\mathcal{P}(E)$ en discret, la tribu borélienne en continu.
- Lorsque X est une variable discrète, la séquence d'évènements $\{X = x\}$ forme une partition de Ω. On l'appelle partition engendrée par X.

Exemples

Exemple

lancer d'un dé régulier. $(\Omega, \mathcal{P}(\Omega), P)$ est un espace probabilisé. Soit X la fonction de Ω dans $\{0, 1\}$ valant 1 si le lancer est pair , 0 sinon. X est une fonction du résultat de l'expérience et elle est mesurable. En effet, $\mathcal{B} = \{\{0\}, \{1\}, \{0, 1\}, \emptyset\}$. On a :

- $\{X = 0\} = \{1, 3, 5\} \in \mathcal{P}(\Omega)$
- $\{X = 1\} = \{2, 4, 6\} \in \mathcal{P}(\Omega)$
- $\{X \in \{0, 1\}\} = \{X = 0 \text{ ou } X = 1\} = \Omega \in \mathcal{P}(\Omega)$
- $\{X \in \emptyset\} = \emptyset \in \mathcal{P}(\Omega)$

Exemple

On fait l'expérience E : " on lance 2 pièces de monnaie régulières ". Soit X le nombre de ń P ż obtenu : X prend les valeurs quantitatives discrètes 0, 1 ou 2 ($E = \{0, 1, 2\}$), selon le résultat de l'expérience :

- $\omega = (F, F)$ alors $X(\omega) = 0$
- $\omega = (F, P)$ ou $\omega = (P, F)$ alors $X(\omega) = 1$
- $\omega = (P, P)$ alors $X(\omega) = 2$

X est donc une variable aléatoire discrète.

- L'évènement engendré par la valeur 0 est l'évènement $\{X = 0\} = \{(F, F)\}$
- L'évènement engendré par la valeur 1 est l'évènement $\{X = 1\} = \{(F, P), (P, F)\}$
- L'évènement engendré par la valeur 2 est l'évènement $\{X = 2\} = \{(P, P)\}$

On a : $\{X = 0\} \cup \{X = 1\} \cup \{X = 2\} = \Omega$

Exemples

Exemple

Soit X l'abscisse de la mine : X prend des valeurs quantitatives continues entre 0 et l ($E = [0, l]$), selon le résultat de l'expérience : si le résultat de l'expérience est $\omega = (x, y)$, $X(\omega) = x$. On associe à E et à Ω les tribus boréliennes $\mathcal{A}$ et $\mathcal{B}$ respectivement engendrées par les ouverts de $[0, l]$ et de $[0, l] \star [0, L]$ (qui contiennent tous les intervalles associés à ces ensembles). Alors, l'image réciproque de tout élément de $\mathcal{B}$ (tout intervalle I de $[0, l]$ est dans $\mathcal{A}$ (c'est un intervalle de $[0, l] \star [0, L]$)
$\{X \in I\} = \{\omega = (x, y), x \in I,\ y \in [0, L]\} \in \mathcal{B}$
X est donc une variable aléatoire (continue).

Variable aléatoire réelle (v.a.r) : Loi

Loi d'une variable aléatoire :

La mesurabilité de X assure que l'image réciproque de tout élément $B \in \mathcal{B}$ est dans $\mathcal{A}$ donc possède une probabilité. On peut ainsi définir, sur $(E, \mathcal{B})$une mesure de probabilité, appelée loi de X et notée P_X par

$$\forall B \in \mathcal{B},\ P_X(B) = P(X^{-1}(B) = P(X \in B))$$

Variable aléatoire réelle v.a.r.) : Loi

variable aléatoire réelle discrète

- **Définition** : X prend ses valeurs dans un ensemble E discret de valeurs réelles (v.a.r.d.).
- **Loi** : Séquence des probabilités : $P_X(x) = P(X = x), x \in E$
- **Propriétés** :
  - $0 \leq p_X(x) \leq 1$
  - $\sum_{x \in E} p_X(x) = 1$
  - $\forall B \subset \mathcal{B}, p_X(B) = \sum_{x \in B} p_X(x)$

variable aléatoire réelle continue

- **Définition** : X prend ses valeurs dans un ensemble E continu de valeurs réelles (v.a.r.c.).
- **Loi** : $\forall x \in E, P(X = x) = 0$. Par contre $P(X \in [x, x + \mathrm{d}x[) \neq 0$. La loi de X est via la fonction f de $\mathbb{R}$ dans $\mathbb{R}$, appelé densité de probabilité : $f(x) = P(X \in [x, x + \mathrm{d}x[)$
- **Propriétés** :
  - $0 \leq f(x)$
  - $\int_{x \in \mathbb{R}} f(x)\mathrm{d}x = 1$
  - $\forall B \subset \mathcal{B}, p_X(B) = \int_{x \in B} f(x)\mathrm{d}x$

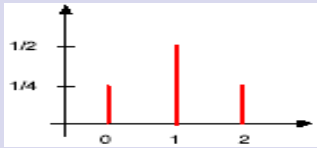
Variable aléatoire réelle v.a.r. : Loi

variable aléatoire réelle discrète

- **Présentation** : la loi de X est présentée dans un tableau (tableau de la loi de X ou tableau en fréquences) :

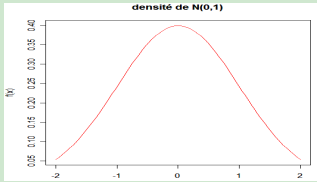
x_i	0	1	2
p_i	1/4	1/2	1/4

- **Représentation graphique** :diagramme en bâtons



variable aléatoire réelle continue

- **Présentation** : la loi de X est donnée par la fonction f
- **Représentation graphique** : courbe de la densité



Variable aléatoire réelle (v.a.r). : Loi

Fonction de répartition de la loi de X

- **Définition** :
$$\begin{array}{rccc} F & : & \mathbb{R} & \to & [0,1] \\ & & x & \mapsto & P(X \leq x) \end{array}$$
- **Propriétés** :

(i) F est croissante

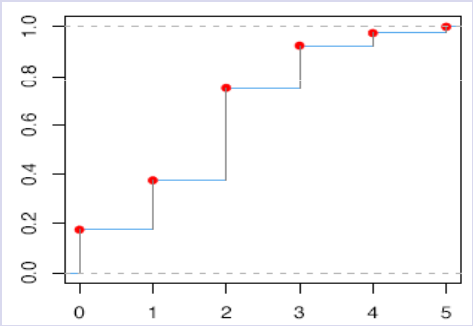
(ii) F est continue à droite

(iii) $\lim\limits_{x \to +\infty} F(x) = 1$ et $\lim\limits_{x \to -\infty} F(x) = 0$

Variable aléatoire réelle (v.a.r.) : Loi

variable aléatoire réelle discrète

- **Forme de F** : F est une fonction en escalier, continue à droite

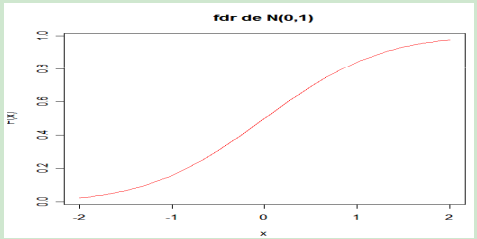


- **Propriétés** :
  - $F(x) = \sum_{y \leq x,\ y \in E} P_X(y)$
  - $P(a \leq X < b) = F(b) - F(a)$
  - $P(X > x) = 1 - F(x)$

Variable aléatoire réelle (v.a.r.) : Loi

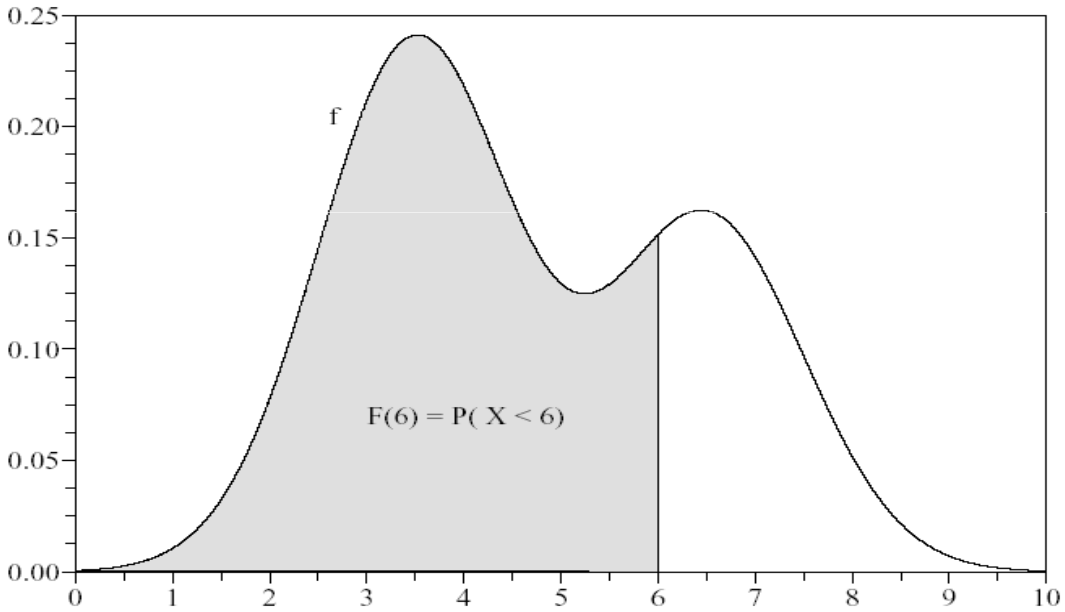
variable aléatoire réelle continue

- **Forme de F :** F est une fonction continue



- **Propriétés** :
  - $F'(x) = f(x)$
  - $F(x) = \int_{-\infty}^{x} f(t)\mathrm{d}t$ =Aire sous la courbe de la densité avant x
  - $P(a \leq X < b) = P(a \leq x \leq b) = F(b) - F(a) = \int_{a}^{b} f(x)\mathrm{d}x$
  - $P(X > x) = P(X \geq x) = 1 - F(x) = \int_{x}^{+\infty} f(t)\mathrm{d}t$

Variable aléatoire réelle (v.a.r.) : Loi



Variable aléatoire réelle (v.a.r) : moments

variable aléatoire réelle discrète

- Espérance d'une v.a.r.d. $E(X) = \sum_{x \in E} x p_X(x)$
- Espérance de $Y = g(X)$, X v.a.r.d. $E(Y) = \sum_{x \in E} g(x) p_X(x)$

variable aléatoire réelle continue

- Espérance d'une v.a.r.c. $E(X) = \int_{\mathbb{R}} x f(x) \mathrm{d}x$
- Espérance de $Y = g(X)$, X v.a.r.c. $E(Y) = \int_{\mathbb{R}} g(x) f(x) \mathrm{d}x$

Propriétés

- $E(a) = a$
- $E(aX) = aE(X)$
- $E(aX + bY) = aE(X) + bE(Y)$
- $E(XY) = E(X)E(Y)$ si X et Y des v.a. indépendantes

Remarque : L'espérance peut ne pas exister

Variable aléatoire réelle (v.a.r) : moments

Définitions

- **Variance de X** : $V(X) = \sigma_X^2 = E((X - E(X))^2)$, $V(X) \geq 0$
- **Écart-type de** X : $\sigma_X = \sqrt{V(X)}$, $\sigma_X \geq 0$

Propriétés

- **Théorème de Koenig** : $V(X) = E(X^2) - (E(X))^2$
- $V(X + a) = V(X)$
- $V(aX + b) = a^2 V(X)$
- $V(X) = 0$ alors $X =$ *constante* p.s.

Exemples

Si l'on considère la constitution d'une fratrie de deux enfants, l'espace fondamental est constitué des évènements élémentaires suivant :

$$\Omega = \{GG, GF, FG, FF\}$$

Les valeurs possibles prises par la variable aléatoire X, " nombres de fille dans la famille " sont : $X(\Omega) = \{0, 1, 2\}$
Dans le cas de la constitution d'une fratrie de deux enfants, si l'on fait l'hypothèse que la probabilité d'avoir un garçon est égale à celle d'avoir une fille $(1/2)$, alors la distribution de probabilité ou loi de probabilité du nombre de filles dans une fratrie de deux enfants est :

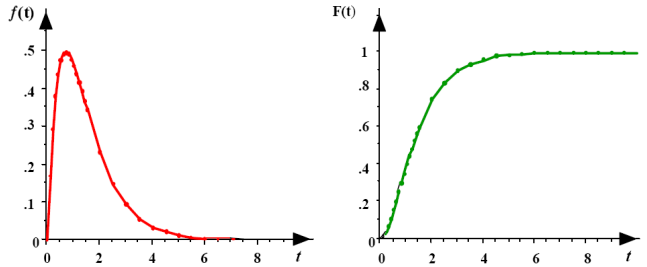
Ω	X	$P(X = x_i)$ ou p_i
G et G	0	1/4
F et G ou G et F	1	1/2
F et F	2	1/4

Ω :Ensemble des évènements possibles
X : Valeurs de la variable aléatoire
$P(X = x_i)$ ou p_i : Probabilités associées à la variable X
Remarque : Une loi de probabilité n'est établie que si $\sum_i p_i = 1$,la somme étant étendue à tous les indices i.

l'espérance de la variable aléatoire " nombre de filles " est : $E(X) = 0 * 1/4 + 1 * 1/2 + 2 * 1/4 = 1$ d'où $E(X) = 1$ Si l'on observe un nombre suffisant de fratries de 2 enfants, on attend **en moyenne** une fille par fratrie.
Quelle est la variance ? Quelle est la fonction de répartition ?

Exemples

Dans une population de canards colverts, lors d'une alerte, l'ensemble des individus quittent leur lieu de repos. Ainsi à $t = 0$, la surface de l'étang est déserte et la probabilité qu'un canard regagne l'étang entre les temps t_1 et t_2 (en minutes) est donnée par : $\int_{t_1}^{t_2} f(t)\,\mathrm{d}t$ avec $f(t) = 2e^{-t} - 2e^{-2t}$ qui représente la fonction densité de probabilité.
La primitive de $f(t)$, $F_T(t)$, fonction de répartition est de la forme :



(a) Fonction de densité de probabilité (b) Fonction de répartition

L'évolution de la recolonisation de l'étang par les *canards colverts* en fonction du temps est donnée par la **courbe rouge**. On observe ainsi que plus de 50 % des canards se posent sur l'étang au cours des 2 premières minutes qui suivent l'alerte. Au bout de 7 minutes, tous les canards ont regagné l'étang. La distribution des probabilités cumulées est donnée sur la **courbe verte**.
Déterminer l'espérance et la variance.
la durée moyenne pour la recolonisation est : $E(T) = \int_0^{+\infty} tf(t)\,\mathrm{d}t = \int_0^{+\infty} 2e^{-t} - 2e^{-2t}\,\mathrm{d}t = 3/2$. Sous ce modèle, la durée moyenne de recolonisation pour l'ensemble de la population de canards colverts est de 1,5 minutes.
La variance de la loi de probabilité est : $V(T) = \int_{-\infty}^{+\infty}(t - E(T))^2 f(t)\,\mathrm{d}t = 5/4$ avec $\sigma = 1,12$

Variable aléatoire réelle (v.a.r) : couples de v.a.r.

Définitions

On appelle couple de variables aléatoires, deux variables aléatoires X et Y définies sur le même univers (issues de la même expérience) à valeurs respectivement dans E et F.

Loi jointe d'un couple de variables aléatoires :

- **Cas discret** : c'est la séquence $(P(\{X = x\} \cap \{Y = y\}))_{x \in E, y \in F}$
- **Cas continu** : c'est la fonction f de $\mathbb{R}^2$ dans $\mathbb{R}$, appelée densité jointe telle que $f(x, y)\mathrm{d}x\mathrm{d}y = P(X \in [x, x + \mathrm{d}x] \cap Y \in [y, y + \mathrm{d}y])$

Lois marginales de X

- **Cas discret** : $P(X = x) = \sum_{y \in F} P(X = x, Y = y)$
- **Cas continu** : c'est la fonction f de $\mathbb{R}^2$ dans $\mathbb{R}$, appelée densité jointe telle que $f(x) = \int_{-\infty}^{+\infty} f(x, y)\mathrm{d}y$

Lois conditionnelles de Y sachant $X = x$

- **Cas discret** : $P(Y = y/X = x) = \dfrac{P(X = x, Y = y)}{P(X = x)}, \ \forall y \in F$
- **Cas continu** : $f(y/x) = \dfrac{f(x, y)}{f(x)}, \ \forall y \in F$

Variable aléatoire réelle (v.a.r) : couples de v.a.r.

Espérance conditionnelle

L'espérance conditionnelle $E(Y/X)$ est une variable aléatoire de même loi que X, dont les réalisations possibles sont les valeurs $\{E(Y/X=x)\}_{x\in E}$, valeurs des espérances des lois conditionnelles de $Y/X=x$

- **Cas discret** : $E(Y/X=x)=\sum_{y\in F} yP(Y=y/X=x),\ \forall x\in E$

$E(Y/X)$	$E(Y/X=x_1)$	$\cdots$	$E(Y/X=x_n)$
$P(E(Y/X)=x)$	$P(X=x_1)$	$\cdots$	$P(X=x_n)$

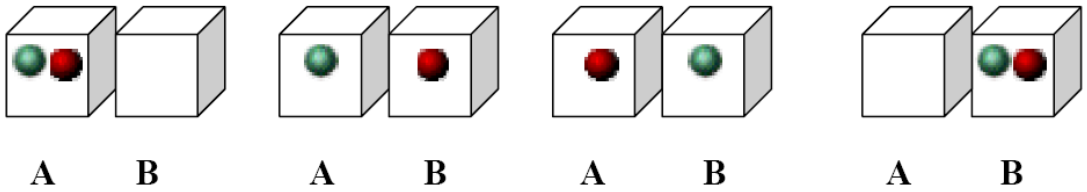
- **Cas continu** : $E(Y/X=x)=\int_{\mathbb{R}} yf(y/X=x)\mathrm{d}y$ prise avec la densité $f(x)$.

Propriété

L'espérance de l'espérance conditionnelle est $E(E(Y/X))=E(Y)$.

Exemple

On place au hasard deux billes rouge et verte dans deux boites A et B. On note X, la variable aléatoire "nombre de billes dans la boite A " et Y, la variable aléatoire " nombre de boites vides " .



Les distributions de probabilités associées à chacune des variables X et Y ainsi que celle de la loi jointe sont indiquées ci-dessous. Pour chaque loi, la valeur de l'espérance et de la variance est également indiquée.

x_i	0	1	2
p_i	1/4	1/2	1/4

Variable X : $X(\Omega) = \{0, 1, 2\}$ dans ce cas $E(X) = 1$ et $V(X) = 1/2$

y_i	0	1
q_i	1/2	1/2

Variable Y : $Y(\Omega) = \{0, 1\}$ dans ce cas $E(Y) = 1/2$ et $V(Y) = 1/4$

$x_i y_j$	0	1	2
$\rho_i j$	3/4	0	1/4

Variable XY : $XY(\Omega) = \{0, 1, 2\}$ dans ce cas $E(XY) = 1/2$ et $V(XY) = 3/4$

Remarque : L'application réciproque n'est pas vraie. La relation $E(XY) = E(X)E(Y)$ n'implique pas forcément l'indépendance de deux variables aléatoires.

La relation $E(XY) = E(X)E(Y)$ est vérifiée car : $E(X) = 1$; $E(Y) = 1/2$ et $E(XY) = 1/2$ cependant les variables aléatoires X et Y ne sont pas indépendantes.

En effet $\rho_0 0 = P((X = 0) \cap (Y = 0)) = 0$ car il est impossible d'avoir à la fois aucune bille dans la boite A et aucune boite vide. Or on attend si X et Y sont deux variables statistiquement indépendantes, à ce que

$$P((X = 0) \cap (Y = 0)) == P(X = 0)P(Y = 0) = 1/4 * 1/2 = 1/8 \neq 0$$

Couples de Variable aléatoire réelle (v.a.r) : Covariance

Lorsque l'on considère deux variables aléatoires simultanément, il faut définir un indicateur de leur " liaison " qui complète les paramètres qui les caractérisent chacune séparément (espérance mathématique et variance).

Définition

Si X et Y sont deux variables aléatoires définies sur le même univers Ω, on appelle **covariance** de ces deux variables, le réel : $Cov(X, Y) = E((X - E(X))(Y - E(Y)))$

Propriétés

- **Théorème de Koenig généralisé** : $Cov(X, Y) = E(XY) - E(X)E(Y)$
- $Cov(X, Y) = Cov(Y, X)$
- $Cov(aX + bY, Z) = aCov(X, Z) + bCov(Y, Z)$
- $Cov(X, aY + bZ) = aCov(X, Y) + bCov(X, Z)$
- $Cov(a, Y) = Cov(Y, a) = 0$
- $V(aX + bY) = a^2 V(X) + b^2 V(Y) + 2abCov(X, Y)$

Couples de Variable aléatoire réelle (v.a.r) : Corrélation

Définition

Le coefficient de corrélation est le réel : $\rho(X,Y) = \dfrac{cov(X,Y)}{\sigma(X)\sigma(Y)}$ où

$\rho(X,Y) = Cov(X^\star, Y^\star)$ Où $X^\star = \dfrac{X - E(X)}{\sigma(X)}$ et $Y^\star = \dfrac{Y - E(Y)}{\sigma(Y)}$ sont les variables centrées-réduites associées à X et Y.

Propriétés

- $-1 \leq \rho(X,Y) \leq 1$ D'autant plus proche de 1 en valeur absolu que le lien linéaire est fort entre X et Y.
- $\mid \rho(X,Y) \mid = 1$ Lien linéaire parfait : $Y = aX + b$
- $\mid \rho(X,Y) \mid = 0$ Absence de lien linéaire (pas forcement indépendance entre X et Y) $\Rightarrow Cov(X,Y) = 0$ d'où $V(X+Y) = V(X) + V(Y)$ et $E(XY) = E(X)E(Y)$

Plan

3. Lois usuelles
   - Lois discrètes
     - Loi uniforme discrète
     - Loi Bernoulli
     - Loi Binomiale
     - Loi Géométrique
     - Loi Hypergéométrique
     - Loi de Poisson
     - Approximations de loi discrète
   - Lois continues
     - Loi uniforme continue
     - Loi exponentielle
     - Loi Normale
     - Approximation de la loi binomiale par la loi normale
     - Théorèmes limites

Loi uniforme discrète

Définition

Une distribution de probabilité suit une **loi uniforme discrète** lorsque toutes les valeurs prises par la variable aléatoire sont **équiprobables** (avec la même probabilité). Si n est le nombre de valeurs différentes prises par la variable aléatoire,

$$\forall i \in \{1, \cdots, n\},\ P(X = x_i) = \frac{1}{n}$$

Espérance et variance

$x_i = i\ \forall i \in [1, n]$ ou $X(\Omega) = \{1, \cdots, n\}$

L'espérance : $E(X) = \dfrac{n+1}{2}$

La variance : $V(X) = \dfrac{n^2 - 1}{12}$

Loi uniforme discrète

Éléments de calcul pour l'espérance et la variance :

$$\sum_{i=1}^{n} i = \frac{n(n+1)}{2} \text{ et } \sum_{i=1}^{n} i^2 = \frac{n(n+1)(2n+1)}{6}$$

Exemple

On lance un dé régulier. Soit X la v.a. qui représente le numéro apparaissant sur le dé. Quelle est la loi de probabilité X ? Déterminer l'espérance et la variance ?

Loi Bernoulli

Définition

Soit un univers Ω constitué de deux éventualités, S pour succès et E pour échec sur lequel on construit une variable aléatoire discrète, « nombre de succès » telle que au cours d'une épreuve :
Si E est réalisé, $X = 0$, $P(X = 0) = q$
Si S est réalisé, $X = 1$, $P(X = 1) = p$ avec $p + q = 1$.
Cette variable aléatoire à deux issues est appelé la variable de Bernoulli. La **loi de probabilité** associée à la variable de Bernoulli X est appelée **loi de Bernoulli** de paramètre p et est notée : $X \sim \mathcal{B}(1, p)$.

Espérance et variance

$X(\Omega) = \{0, 1\}$
L'espérance : $E(X) = p$
La variance : $V(X) = pq$

Loi Bernoulli

Exemple

On jette une pièce de monnaie équilibrée. Soit X la v.a. qui représente les faces de la pièce. Quelle est la loi de probabilité de X ? Déterminer l'espérance et la variance ?

Loi Binomiale

Définition

Soit l'application $S_n : \Omega^n \to \{0, 1, \cdots, n\}$ avec
$S_n = X_1 + X_2 + \cdots + X_i + \cdots + X_n$ où X_i est une variable de **Bernoulli**.
La **variable**, S_n , représente le **nombre de succès** obtenus lors de la répétition de n épreuves **identiques et indépendantes**, chaque épreuve ne pouvant donner que deux résultats possibles. La variable S_n est appelé une variable **binomiale** .
La **loi de probabilité** associée à la variable de Binomiale S_n est appelée la **loi de Binomiale** de paramètres n et p et est notée : $S_n = \sum_{i=1}^{n} X_i \sim \mathcal{B}(n, p)$.

La loi de probabilité est : $P(S_n = k) = C_n^k p^k q^{n-k}$

Espérance et variance

$X(\Omega) = \{0, 1, \cdots, n\}$
L'espérance : $E(X) = np$
La variance : $V(X) = npq$

Loi Binomiale

Exemple

On jette 10 fois de suite une pièce de monnaie équilibrée. Quelle est la probabilité d'avoir un total de 8 piles ? Donnez l'espérance et la variance de X la v.a. qui associe à ces 10 lancers de pièce le nombre de pile ?

Loi Géométrique

Définition

Soit X le nombre d'essais de Bernoulli nécessaires pour obtenir un premier succès. La loi de la variable aléatoire discrète X porte le nom de loi de **loi Géométrique** de paramètre p telle que : $P(X = k) = pq^{k-1}$ avec $k \in \mathbb{N}^*$avec $q = 1 - p$

La **loi Géométrique** de paramètre p est notée : $X \sim \mathcal{G}(p)$.

Espérance et variance

$X(\Omega) = \{1, 2, \cdots\}$

L'espérance : $E(X) = \dfrac{1}{p}$

La variance : $V(X) = \dfrac{q}{p^2}$

Loi Géométrique

Exemple

Supposons des clients qui achètent des melons au rayon légumes du supermarché. 30 % d'entre eux ont préalablement senti leur melon. Donner la loi de probabilité de X, ainsi que $E(X)$ et $V(X)$. Quelle est la probabilité que le quatrième client soit le premier à humer son achat ?

Loi Hypergéométrique

Définition

On tire **sans remise** n objets d'un ensemble de N objets dont m possèdent une caractéristique particulière (et les autres $N-m$ ne la possèdent pas). Soit X le nombre d'objets de l'échantillon qui possèdent la caractéristique. La loi de la variable aléatoire discrète X porte le nom de loi de **loi Hypergéométrique** de paramètres N, n, m telle que :

$$P(X=k) = \frac{C_m^k C_{N-m}^{n-k}}{C_N^n} \text{ avec } k = \max(0, n-N+m), \cdots, \min(n, m).$$

La **loi Hypergéométrique** de paramètre N, n, m est notée :
$X \sim \mathcal{H}(N, n, m)$.

Espérance et variance

L'espérance : $E(X) = n\frac{m}{N}$

La variance : $V(X) = n\frac{m}{N}\left(1-\frac{m}{N}\right)\left(\frac{N-n}{N-1}\right)$

Loi Hypergéométrique

Exemple

Une boîte contient 8 composants parmi lesquels 2 sont défectueux. Trois composants sont pris au hasard et sans remise de la boîte. Soit X le nombre de composants défectueux dans l'échantillon. Donner la loi de probabilité de X, ainsi que $E(X)$ et $V(X)$.

Loi de Poisson

La **loi de Poisson** ou la loi des **évènements rares** s'applique souvent aux phénomènes accidentels où la probabilité p est très faible ($p < 0,05$). Elle peut également dans certaines conditions être définie comme **limite d'une loi binomiale**.
Cette loi est souvent utilisée dans la modélisation des files d'attente : nombre de clients en attente à une caisse de supermarché, nombre de conducteurs passés à un péage pendant une période de temps, des pannes de machines, des accidents d'avions, des fautes dans un texte, etc

Définition

Soit X une v.a. à valeurs dans $\mathbb{N}$. On dit que X suit une **loi de Poisson** de paramètre $\lambda (\lambda \in \mathbb{N}^+)$, notée $\mathcal{P}(\lambda)$, si :

$$\forall k \in \mathbb{N},\ P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

.
La **loi de Poisson** de paramètre λ et est notée : $X \sim \mathcal{P}(\lambda)$.

Espérance et variance

L'espérance : $E(X) = \lambda$
La variance : $V(X) = \lambda$

Loi de Poisson

Exemple

A un guichet d'une banque, on sait que le nombre moyen de clients par heure est de 12. On suppose que le nombre de clients par heure est distribué selon une loi de Poisson. Quelle est la probabilité pour qu'en une heure, le guichetier s'occupe de plus de 15 clients ? Donner la loi de probabilité de X, ainsi que $E(X)$ et $V(X)$.

Approximation d'une loi hypergéométrique par une binomiale

Approximation

Soit $X \sim \mathcal{H}(N, n, m)$. Si n/N est petit alors X suit approximativement une loi binomiale $\mathcal{B}(n, p)$, où $p = \dfrac{m}{N}$:

$$P(X = k) = \frac{C_m^k C_{N-m}^{n-k}}{C_N^n} \simeq C_n^k \left(\frac{m}{N}\right)^k \left(1 - \frac{m}{N}\right)^{n-k}$$

pour $k = 0, 1, 2, \cdots, n$
(on suggère $n/N < 0,1$).

Approximation d'une loi binomiale par une Poisson

Approximation

Soit $X \sim \mathcal{B}(n, p)$. Si n est grand et p est petit (de sorte que np est modéré) alors X suit approximativement une loi de Poisson $\mathcal{P}(\lambda)$ où $\lambda = np$:

$$P(X = k) = C_n^k p^k (1-p)^{n-k} \simeq \frac{e^{-np}(np)^k}{k!}$$

pour $k = 0, 1, 2, \cdots$
(on suggère $n > 20$ et $p < 0,05$).

Plan

3. Lois usuelles
   - Lois discrètes
     - Loi uniforme discrète
     - Loi Bernoulli
     - Loi Binomiale
     - Loi Géométrique
     - Loi Hypergéométrique
     - Loi de Poisson
     - Approximations de loi discrète
   - Lois continues
     - Loi uniforme continue
     - Loi exponentielle
     - Loi Normale
     - Approximation de la loi binomiale par la loi normale
     - Théorèmes limites

Loi uniforme continue

Définition

La loi uniforme est la loi exacte de phénomènes continus uniformément répartis sur un intervalle. La variable aléatoire X suit une **loi uniforme** sur le segment $[a, b]$ avec $a < b$ si sa densité de probabilité est donnée par :

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & \text{si} x \in [a, b] \\ 0, & \text{ailleurs} \end{cases}.$$

La **loi uniforme continue** est notée $X \sim \mathcal{U}_{[a,b]}$.

Espérance et variance

L'espérance : $E(X) = \dfrac{b+a}{2}$

La variance : $V(X) = \dfrac{(b-a)^2}{12}$

La fonction de répartition est : $F_X(x) = \begin{cases} 0, & \text{si } x < a \\ \frac{x-a}{b-a}, & \text{si } a \leq x \leq b \\ 1, & \text{ailleurs} \end{cases}$.

Loi uniforme continue

Exemple

On considère que la mesure d'un caractère biologique chez des patients suit une loi uniforme sur l'intervalle continu $[0, 20]$.

1. Quelle est la probabilité d'avoir une mesure entre 14 et 18 ?
2. Quelle est la probabilité d'avoir une mesure entre 4 et 8 ?

Loi exponentielle

La loi exponentielle modélise la survie au sens large (être humains, appareils,pièces mécaniques, etc.).
X : temps de survie : $P(X \geq x) = e^{-\lambda x} = S(x)$

Définition

Soit X la variable aléatoire continue définie sur un intervalle $[0, +\infty[$. Si sa densité de probabilité est donnée par :

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{si} x \geq 0 \\ 0, & \text{ailleurs} \end{cases}.$$

La **loi exponentielle** de paramètre λ est notée $X \sim \mathcal{E}(\lambda)$.

Espérance et variance

L'espérance : $E(X) = \dfrac{1}{\lambda}$

La variance : $V(X) = \dfrac{1}{\lambda^2}$

La fonction de répartition est : $F_X(x) = \begin{cases} 1 - e^{-\lambda x}, & \text{si } x \geq 0 \\ 0, & \text{ailleurs} \end{cases}.$

Loi exponentielle

Exemple

Le temps de survie de patients atteints d'un certain cancer peut être modélisé par une loi exponentielle de moyenne 2 ans. Soit X une v.a.r. qui associe à un patient sa durée de survie en années.

- Quelle est la probabilité de survivre au bout d'un an ? 2 ans ? 5 ans ?

Généralité

On parle de **loi normale** lorsque l'on a affaire à une variable aléatoire continue dépendant d'un grand nombre de causes indépendantes dont les effets s'additionnent et dont aucune n'est prépondérante (conditions de Borel). Cette loi acquiert sa forme définitive avec **Gauss** (en 1809) et **Laplace** (en 1812). C'est pourquoi elle porte également les noms de : **loi de Laplace, loi de Gauss et loi de Laplace-Gauss**.
Elle jouit d'une importance fondamentale car un grand nombre de méthodes statistiques reposent sur elle. Ceci est lié au fait qu'elle intervient comme loi limite dans des conditions très générales. Pour faire ressortir toute son importance et sa forme, **Youden W.J.**, du National Bureau of Standards, a eu l'ingénieuse idée de la présenter telle qu'elle apparaît ci-dessous.

La
loi normale
des erreurs
constitue l'une
des généralisations
les plus étendues de
la philosophie naturelle
dans l'histoire de l'humanité.
Elle est un outil précieux pour la
recherche en sciences physiques et
sociales ainsi qu'en médecine, en agriculture
et en génie. Elle est indispensable à l'analyse et à
l'interprétation des données obtenues par l'observation ou
l'expérience.

Loi Normale

Exemple d'application

- Ainsi la taille corporelle d'un animal dépend des facteurs environnementaux (disponibilité pour la nourriture, climat, prédation, etc.) et génétiques. Dans la mesure où ces facteurs sont indépendants et qu'aucun n'est prépondérant, on peut supposer que la taille corporelle suit une loi normale.
- En métrologie, pour la distribution des erreurs d'observation.
- En météorologie, pour la distribution de phénomènes aléatoires tels que la température et la pression.
- En biologie, pour la distribution de caractères biométriques comme la taille ou le poids d'individus appartenant à une population homogène. En technologie, pour la distribution des cotes des pièces usinées.
- En économie, pour les fluctuations accidentelles d'une grandeur économique (production, ventes, ...) autour de sa tendance, etc.....

Loi Normale

Définition

Soit X une la variable aléatoire continue définie sur $\mathbb{R}$.
Si sa densité de probabilité est donnée par :

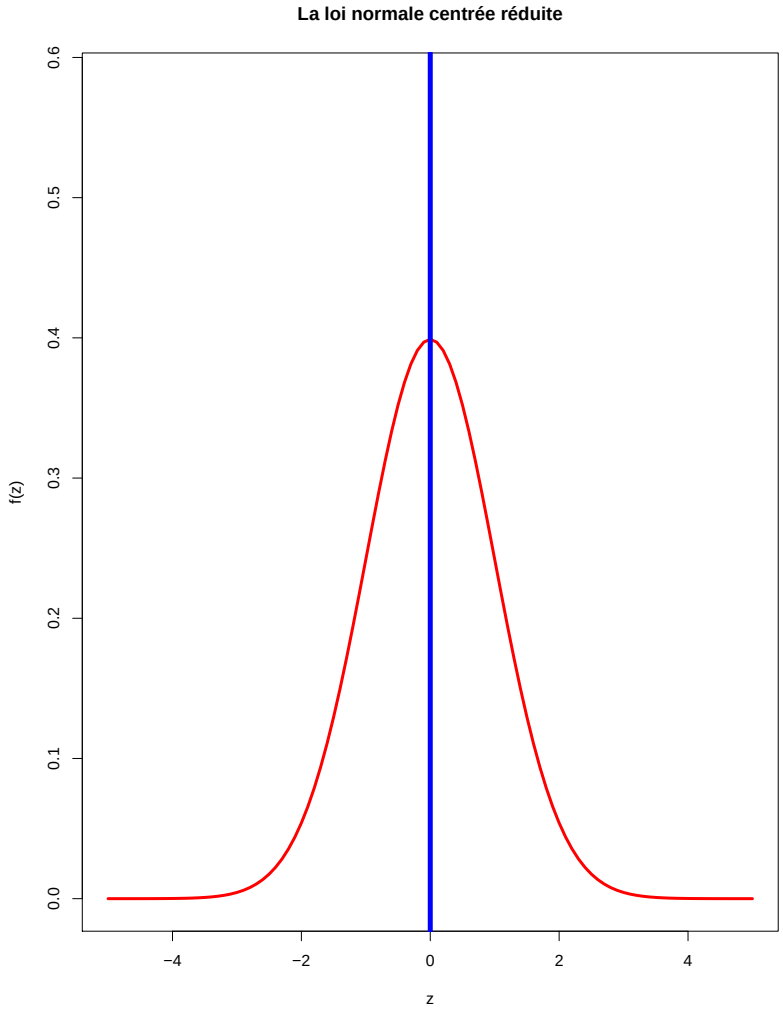
$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$$

avec $\mu \in \mathbb{R}$ et $\sigma \in \mathbb{R}^+$
La **loi normale** de paramètre $(\mu; \sigma)$ est notée $X \sim \mathcal{N}(\mu, \sigma)$.

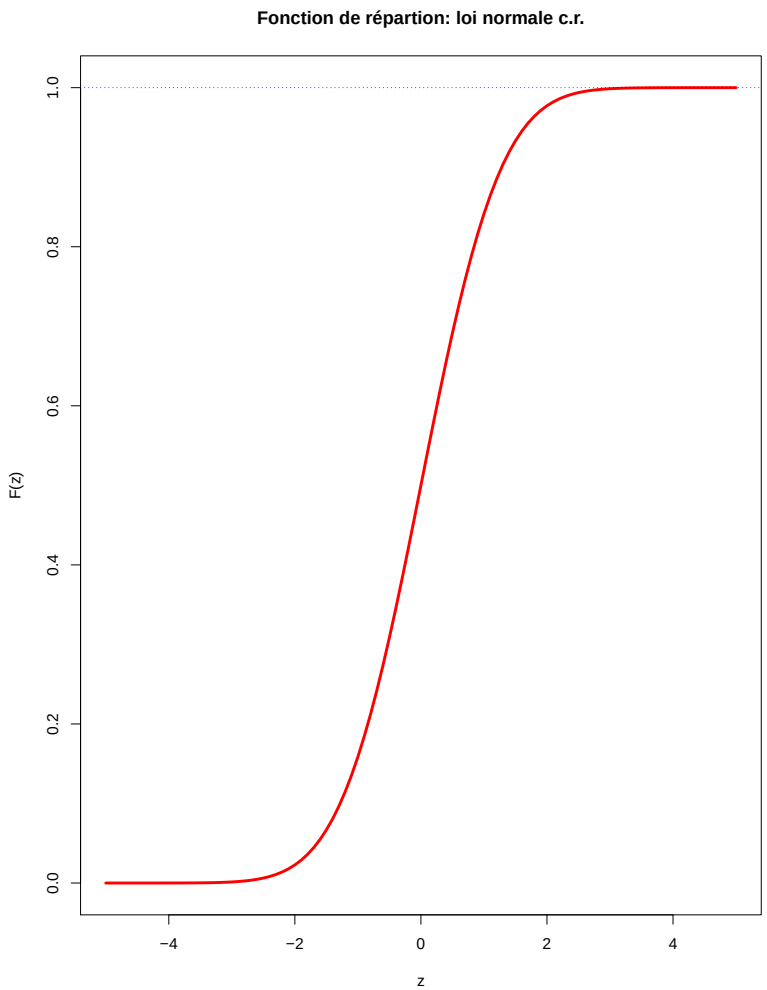
Espérance et variance

- L'espérance : $E(X) = \mu$
- La variance : $V(X) = \sigma^2$
- $\lim\limits_{x \to \pm\infty} f_X(x) = 0$
- Cette loi est symétrique par rapport à μ : $F_X(-x) = 1 - F_X(x)$ et $f_X(\mu + x) = f_X(\mu - x)$ (symétrie par rapport à l'axe $x = \mu$).
- f_X atteint son maximum en $x = \mu$ (μ est le mode de X)
- Les points d'inflexion du graphe de f_X sont $x = \mu \pm \sigma$.

Représentation graphique de loi Normale centrée-réduite



Représentation graphique de la fonction de répartition de la loi Normale centrée-réduite



Loi Normale

Fonction de répartition

La fonction de répartition est :

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}(\frac{t-\mu}{\sigma})^2} \, \mathrm{d}t.$$

Problème

$F_X(x)$ n'a pas d'expression explicite (analytique) en fonction de x ! !

Solution

- Nécessité d'utiliser des tables
- Méthode des trapèzes : autant de calculs de lois possibles
- On utilise une normalisation (centrée-réduite, standardisation) pour utiliser une seule table

Loi Normale centrée-réduite

Définition

Soit X une variable aléatoire continue de moyenne μ et d'écart-type σ. On appelle variable **centrée-réduite** ou **standardisée** la v.a. Z définie par

$$Z = \frac{X - \mu}{\sigma}$$

$E(Z) = 0$ (On dit que Z est centrée) et $V(Z) = 1$ (On dit que Z est réduite).

La fonction densité est $f_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2}$

Conséquence

Si $X \sim \mathcal{N}(\mu, \sigma)$ alors $Z \sim \mathcal{N}(0, 1)$

- La fonction de répartition de Z, notée $\Phi(z)$, est tabulée
- Souvent notée $X^\star$ ou U la variable standardisée

Table de la loi Normale centrée-réduite

Présentation des tables

- **Table de la fonction de répartition $\Phi(z)$ de la loi normale centrée-réduite**

  Cette table indique les probabilités des intervalles sous la forme $]-\infty, z]$ pour des valeurs positives de z.

  C'est la fonction de répartition Φ telle que $\Phi(z) = \int_{-\infty}^{z} f(t)\,\mathrm{d}t$.

  Pour des valeurs négatives de z, on utilise la symétrie de la courbe.

- **Table de distribution de Z, loi normale centrée-réduite**

  On veut déterminer z tel que
  $P(Z \leq z) = \Phi(z) = 1 - \alpha$
  La table donne z_λ en fonction de λ

Table de la loi Normale centrée-réduite

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767

Soit $Z \sim \mathcal{N}(0,1)$: Lecture de la table : Pour $z = 1,24$ (intersection de la ligne $1,2$ et de la colonne $0,04$), on a la proportion $P(Z \leq 1,24) = 0,8925$

$$\Phi(1,24) = \Phi(1.2 + 0,04) = P(Z \leq 1,24) = 0,8925$$

$$\Phi(-1,24) = P(Z \leq -1,24) = P(Z \geq 1,24) = 1 - P(Z \leq 1,24) = 1 - 0,8925 = 0,1075$$

Loi Normale

Exemple

Le poids des bébés à la naissance suit une loi normale de moyenne 3,3 Kg et d'écart-type 0,6 Kg. On note X la variable aléatoire "poids des bébés à la naissance".

- Calculer la probabilité que $2,12 \leq X \leq 4,48$
- Déterminer la limite du poids correspondant aux 10% des bébés les plus gros.

Loi Normale

Additivité

Soit $X_1, X_2, \cdots, X_n$ des variables aléatoires indépendantes avec $X_i \sim \mathcal{N}(\mu_i, \sigma_i)$. pour tout i.
Soit $Y = a_0 + a_1X_1 + a_2X_2 + \cdots + a_nX_n$.
Alors $Y \sim \mathcal{N}(\mu, \sigma)$. où

$$\mu = a_0 + a_1\mu_1 + a_2\mu_2 + \cdots + a_n\mu_n$$

$$\sigma = a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + \cdots + a_n^2\sigma_n^2$$

Approximation de la loi binomiale par la loi normale

Approximation

Soit $\mathcal{B}(n,p)$ une variable aléatoire suivant une loi binomiale. Alors X est la somme de variables de Bernoulli indépendantes de paramètre p.
Si n est grand alors X suit approximativement une loi normale $\mathcal{N}(\mu = np, \sigma = \sqrt{np(1-p)})$.
Cette approximation est bonne si :

- $np > 5$ lorsque $p \leq \frac{1}{2}$.
- $n(1-p) > 5$ lorsque $p > \frac{1}{2}$.

Approximation de la loi binomiale par la loi normale

correction pour la continuité

Puisque $\mathcal{B}(n,p)$ est une variable discrète, on cherche à calculer des probabilités comme $P(X=x)$.
Or ceci n'a pas de sens pour une v.a. continue et on doit corriger la valeur cherchée pour pouvoir utiliser l'approximation de X par une loi normale.
Par exemple

Valeur cherchée	Valeur corrigée
$P(X=x)$	$P(x-\frac{1}{2}\leq X\leq x+\frac{1}{2})$
$P(a\leq X\leq b)$	$P(a-\frac{1}{2}\leq X\leq b+\frac{1}{2})$

Cette correction est appelée *correction pour la continuité*.

Loi des grands nombres

Loi des grands nombres

Soient $X_1, X_2, \cdots, X_n$ des variables aléatoires indépendantes ayant la même distribution, avec $E(X_i) = \mu$ pour $i = 1, 2, \cdots, n$.
Alors pour tout $\epsilon > 0$,

$$\lim_{n \to \infty} P\left[\left|\frac{\sum_{i=1}^{n} X_i}{n} - \mu\right| > \epsilon\right] = 0.$$

Théorème central limite (TCL)

Théorème central limite

Soient $X_1, X_2, \cdots, X_n$ des variables aléatoires indépendantes, avec $E(X_i) = \mu_i$ et $V(X_i) = \sigma_i$ pour $i = 1, 2, \cdots, n$.
Alors la variable aléatoire

$$Z = \frac{\sum_{i=1}^{n}(X_i - \mu_i)}{\sqrt{\sum_{i=1}^{n}\sigma_i^2}}$$

suit approximativement une loi normale $\mathcal{N}(0,1)$ si n est grand.

TCL : cas particulier

Soient $X_1, X_2, \cdots, X_n$ des variables aléatoires indépendantes et identiquement distribuées, avec $E(X_i) = \mu$ et $V(X_i) = \sigma$ pour $i = 1, 2, \cdots, n$.
Alors la variable aléatoire

$$Z = \frac{\sum_{i=1}^{n} X_i - n\mu}{\sigma\sqrt{n}}$$

suit approximativement une loi normale $\mathcal{N}(0,1)$ si n est grand.
Autres formulations (pour $n \to \infty$) :

$$\sum_{i=1}^{n} X_i \sim \mathcal{N}(n\mu, \sigma\sqrt{n})$$

ou

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \sim \mathcal{N}(n\mu, \frac{\sigma}{\sqrt{n}}).$$

TCL : quelle valeur de n est assez grande ?

- Si les lois des Xi sont proches d'une loi normale alors pour $n \geq 4$ l'approximation donnée par le théorème central limite est bonne.
- Si les lois des X_i sont moyennement proches d'une loi normale (p. ex. loi uniforme) alors pour $n \geq 12$ l'approximation donnée par le théorème central limite est bonne.
- Si les lois des X_i ne sont pas proches d'une loi normale alors pour $n \geq 100$ l'approximation donnée par le théorème central limite sera bonne (par exemple fonction de densité très asymétrique).

Quelques conseils pour résoudre les problèmes

Voici, lorsqu'elle s'applique, une méthode de travail qui peut guider votre démarche.

1. Suite à l'énoncé du problème, identifier correctement à l'aide de mots la variable aléatoire que vous allez considérer.
2. Préciser les valeurs possibles que peut prendre cette variable.
3. Identifier correctement la loi de probabilité qu'elle suit en essayant de reconnaître dans le problème une situation type.
4. Déterminer les paramètres de la loi.
5. Utiliser les formules théoriques ou les tables pour déterminer les probabilités demandées. Face à de longs calculs et en l'absence de tables correspondant à vos ou votre paramètre, penser à approcher votre loi par une autre.

Plan

- Loi uniforme discrète
- Loi Bernoulli
- Loi Binomiale
- Loi Géométrique
- Loi Hypergéométrique
- Loi de Poisson
- Approximations de loi discrète
- Loi uniforme continue
- Loi exponentielle
- Loi Normale
- Approximation de la loi binomiale par la loi normale
- Théorèmes limites

4 Statistique descriptive
- Introduction
- Terminologie

- La **statistique** fait intervenir la collecte, la présentation et l'analyse de données, ainsi que leur utilisation dans le but de résoudre des problèmes.
- D'une autre manière, la statistique est une discipline scientifique dont le but est
  - de planifier et recueillir des données pertinentes,
  - d'extraire l'information contenue dans un ensemble de données,
  - de fournir une analyse et une interprétation des données afin de pouvoir prendre des décisions.
- La statistique utilise
  - des notions de probabilités,
  - des notions de mathématiques.

Définition

La **statistique descriptive** est un ensemble de méthodes (représentations graphiques et calculs de caractéristiques numériques) permettant de faire une synthèse statistique de données. Les données à examiner proviennent généralement d'un échantillon.

Plan

- Loi uniforme discrète
- Loi Bernoulli
- Loi Binomiale
- Loi Géométrique
- Loi Hypergéométrique
- Loi de Poisson
- Approximations de loi discrète
- Loi uniforme continue
- Loi exponentielle
- Loi Normale
- Approximation de la loi binomiale par la loi normale
- Théorèmes limites

4 Statistique descriptive

- Introduction
- Terminologie

- L'**univers** est l'ensemble des objets sur lesquels porte l'étude statistique.
- Une **variable** est une caractéristique selon laquelle l'univers est étudié.
- La **population** est l'ensemble de toutes les mesures ou observations de la variable dans l'univers considéré.
- Une **unité expérimentale** est un objet de l'univers, sur lequel la variable est mesurée.
- Un **échantillon** est un sous-ensemble
  - de l'univers : s'il est composé d'unités expérimentales,
  - de la population : s'il est composé de mesures de la variable.
- Un **paramètre** est une mesure caractérisant la variable dans la **population**.
  Par exemple : la moyenne de la population.
  En général, la vraie valeur d'un paramètre est inconnue.
- Une statistique est une mesure caractérisant la variable dans un échantillon de la population.
  Par exemple : la moyenne échantillonnale.
  Une statistique peut être calculée.

Mesure et variable

- Un individu est décrit par un ensemble de critères qu'on appellera **variables** ou **caractères**.
- Lorsqu'on mène une étude statistique on s'intéresse à des **unités statistiques** ou **unités d'observation** :
  par exemple des individus, des entreprises, des ménages. *Dans la pratique, on s'intéresse dans la plupart des cas à un nombre fini d'unités*.
- Sur ces unités, on **mesure** un caractère ou une variable, le chiffre d'affaires de l'entreprise, le revenu du ménage, l'âge de la personne, la catégorie socioprofessionnelle d'une personne, la précipitation.
- On suppose que la variable prend toujours une seule valeur sur chaque unité. Les variables sont désignées par simplicité par une lettre majuscule (X, Y, Z).
- Les valeurs possibles de la variable, sont appelées **modalités**.
- L'ensemble des valeurs possibles ou des modalités est appelé le **domaine de la variable** .

Typologies des variables : qualitatives ou quantitatives.

Variables qualitatives : Ces caractères ne sont pas de nature numérique et aucune opération arithmétique n'est possible (même si, parfois, elles peuvent être codées par un nombre). Les valeurs prises par ces variables sont appelées modalités. On peut distinguer deux types de variables qualitatives :

- **les variables nominales :** ce sont les variables sur lesquels on ne peut faire ni opération arithmétique, ni comparaison. L'échelle nominale est utilisée pour représenter les variables dont les catégories ne sont pas naturellement ordonnées. On peut coder ces catégories par des nombres. *Exemple de variables nominales : l'état civil, le sexe etc*
- **les variables ordinales :** L'échelle ordinale est utilisée pour représenter des variables dont les catégories sont naturellement ordonnées ou en relation les unes par rapport aux autres. Les modalités sont non-quantitatives et indiquent uniquement une position dans une série ordonnée (on ne peut pas mesurer la différence qui existe entre deux positions). *Par exemple, un classement de préférence ou par jugement comme « j'aime un peu », « beaucoup », « pas du tout ».*

Typologies des variables statistiques

Variables quantitatives : Les modalités sont de nature numériques et l'on peut effectuer des opérations arithmétiques et des classements. Elles peuvent être de deux sortes :

- **discrète :** les modalités prennent leurs valeurs dans un ensemble fini ou dénombrable. La mesure est donc toujours exacte. *Par exemple, le nombre d'enfant par famille est une variable discrète.*
- **continue :** ici les variables prennent des valeurs qui peuvent être arbitrairement proche les unes des autres, et une valeur peut être aussi précise que l'on veut. En réalité, comme les mesures sont faites en précision finie, l'échelle continue est une abstraction commode pour modéliser les échelles possédant un grand nombre de valeurs (qui sont théoriquement aussi proche qu'on veut les unes des autres). *Par exemple, la taille est une variable continue*.

Ces définitions sont à relativiser, l'âge est théoriquement une variable quantitative continue, mais en pratique, l'âge est mesuré dans le meilleur des cas au jour près. Toute mesure est limitée en précision !

Exemple

- Les modalités de la variable sexe sont masculin (codé M) et féminin (codé F). Le domaine de la variable est $\{M, F\}$.
- Les modalités de la variable nombre d'enfants par famille sont 0,1,2,3,4,5,. . .C'est une variable quantitative discrète.

Méthodologie

- Une étude statistique débute par la collecte des données : les observations « brutes »sont obtenues après enquête, mesures etc. C'est à ce niveau qu'intervient les méthodes d'**échantillonages** (non abordées dans ce chapitre).
- Une fois les données collectées, et avant d'apporter des réponses précises aux questions posées au préalable de l'étude, il convient d'analyser ces données. Cette analyse à pour but de synthétiser, résumer et structurer l'information contenue dans les données à l'aide de tableaux, graphiques et résumés numériques. C'est l'objet de la **statistique descriptive**, ou exploratoire, qui est l'objet de ce chapitre. Cette analyse se fait sur l'**échantillon** qu'on a à disposition.
- Cette description des données n'est en général pas suffisante. Une bonne étude statistique consiste en formuler et valider des hypothèses relative à la **population totale**. Le but est d'étendre les résultats observés précédement à toute la population, en étudiant le risque d'erreur possible. C'est le but de l'**inférence statistique** (qui ne sera pas abordée dans ce chapitre).

Lien statistique/Probabilité

Il existe des équivalences entre les termes utilisés en statistique et la probabilié (voir le tableau ci-dessous).

Probabilité	**Statistique**
Espace fondamental	Population
Epreuve	Tirage (d'un individu), expérimentation
Evènement élémentaire	Individu, observation
Variable aléatoire	Caractère
Epreuves répétées	Echantillonnage
Nbre de répétitions d'une épreuve	Taille de l'échantillon, effectif total
Probabilité	Fréquence observée
Loi de probabilité	Distribution observée ou loi empirique
Espérance mathématique	Moyenne observée
Variance	Variance observéee

Tableaux statistiques et graphiques

Dans cette section, on considèrera des **échantillons** de taille n, c'est-à-dire n individus $\omega_1, \cdots, \omega_n$ issus d'une population Ω. On notera en majuscule (généralement X ou Y) les variables statistiques. Les modalités des variables statistiques seront notées avec la minuscule correspondante et indicées, s'il y a lieu, par le numéro de la modalité dans le cas discret ou de la classe (ie un ensemble de modalité) dans le cas continue. La modalité prise par la variable X pour l'individu ω_n sera notée $X(\omega_n)$.

Tableaux statistiques

Tableau brut : On considère une étude statistique portant sur un échantillon de taille n individus. On mesure plusieurs variables statistiques, qui peuvent être qualitatives ou quantitatives. La récolte initiale des données conduit à un tableau brut de la forme :

Individus	**variable 1**	**variable 2**	$\cdot$
ω_1	$X(\omega_1)$	$Y(\omega_1)$	$\cdot$
ω_2	$X(\omega_2)$	$Y(\omega_2)$	$\cdot$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
ω_n	$X(\omega_n)$	$Y(\omega_n)$	$\cdot$

Les tableaux des données sont présentés généralement sous cette forme pour analyser les données dans la plus part des logiciels d'analyse de données.

Tableau de contingence

Pour les variables **qualitatives**, on peut construire un tableau de contingence. Ce tableau résume comment une caractéristique dépend d'une autre. Pour des raisons pratiques, on se limite généralement au tableau de contingence de deux variables qualitatives X et Y de modalités respectives $(x_1, \cdots, x_i, \cdots, x_I)$ et $(y_1, \cdots, y_j, \cdots, y_J)$. Ce tableau donne le nombre d'individus possédant simultanément la modalité x_i de la variable X et la modalité y_j de la variable Y. Un tel tableau se présente sous la forme suivante, pour un échantillon de taille n :

XY	y_1	$\cdot$	y_j	$\cdot$	y_J	
x_1	n_{11}		n_{1j}		n_{1J}	$n_{1\bullet}$
$\vdots$			$\vdots$		$\vdots$	$n_{1\bullet}$
x_i	n_{i1}		n_{ij}		n_{iJ}	$n_{i\bullet}$
$\vdots$			$\vdots$		$\vdots$	$n_{1\bullet}$
x_I	n_{I1}		n_{Ij}		n_{IJ}	$n_{I\bullet}$
	$n_{\bullet 1}$		$n_{\bullet j}$		$n_{\bullet J}$	n

où n_{ij} désigne le nombre de fois où X à pris la modalité x_i et Y la modalité y_j. Autrement dit, n_{ij} représente le nombre d'individus qui possède à la fois la caractéristique x_i et la caractéritique y_j. On définit les quantités

$$n_{i\bullet} = \sum_{j=1}^{J} n_{ij} \text{ et } n_{\bullet j} = \sum_{i=1}^{I} n_{ij}$$

qui représentent respectivement le nombre d'individus qui possèdent la modalitée x_i et le nombre d'individus avec la modalitée y_j.

Tableau des fréquences

Variable discrète : On considère une variable qualitative ou qualitative discrète X à valeurs dans $\{x_1, \cdots, x_i, \cdots, x_K\}$. Si X est quantitative ou qualitative ordinale, on suppose ses modalités ordonnées tels que $x_1 < \cdots < x_i < \cdots < x_K$. On commence par définir les quantités descriptives de bases.

Effectif ou fréquence absolue : On appelle effectif ou fréquence absolue **de la modalité x_k le nombre N_k d'individus qui ont pris la modalité x_k** :

$$N_k = \sum_{\omega \in \Omega | X(\omega) = x_k} X(\omega)$$

$$N_k = \sum_{i=1}^{k} n_i$$

Fréquence relative : On appelle fréquence relative (ou simplement fréquence) **de la modalité x_k le nombre f_k définit par** :

$$f_k = \frac{n_k}{n}$$

Fréquence relative cumulée : On appelle fréquence relative cumulée (ou simplement fréquence cumulée) **de la modalité x_k le nombre F_k définit par** :

$$F_k = \sum_{i=1}^{k} f_i$$

$$F_K = \sum_{k=1}^{K} f_k = 1$$

On peut aussi définir les effectifs cumulés :

Effectifs cumulés : On appelle effectif cumulé **de la modalité x_k le nombre N_k définit par** :

$$N_k = \sum_{i=1}^{k} n_i = nF_k$$

La distribution des n observations de X peut être présentée sous la forme d'un tableau de fréquence où figurent, pour chaque modalité x_k, l'effectif n_k, la fréquence relative f_k et la fréquence cumulée F_k :

modalité	**effectif**	**fréquence relative**	**fréquence cummulée**
x_1	n_1	f_1	F_1
$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_k	n_k	f_k	F_k
$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_K	n_K	f_K	F_K

Les fréquences relative et cumulée peuvent être donnée sous forme de pourcentage.

Défauts relevés sur une pièce de tissu : Un fabricant de tissu essaie une nouvelle machine ; il compte le nombre de défauts sur 75 échantillons de 10 mètres. Il a trouvé les résultats suivants :

Nombre k de défauts	0	1	2	3	4	5
Nombre n_k d'échantillons	38	15	11	6	3	2

Nombre d'individus : les 75 échantillons.
Fréquence absolue associée à la valeur k, le nombre n_k : par exemple, sur les 75 échantillons examinés, 11 présentent $k = 2$ défauts, donc si $k = 2$, $n_k = 11$.
Fréquence relative associée à la valeur k : le quotient $\frac{n_k}{n}$.
11/75=0,146 est la fréquence relative associée à la valeur $k = 2$.
Fréquence cumulée absolue associée à la valeur k : le nombre d'échantillons ayant au plus k défauts (k compris).
$38 + 1 + 15 + 1 + 11 = 64$ est la fréquence cumulée absolue associée à la valeur $k = 2$.
Fréquence cumulée relative associée à la valeur k, le nombre d'échantillons ayant au plus k défauts (k compris) divisé par n.
64/75=0,853 est la fréquence cumulée relative associée à la valeur $k = 2$.

- Les fréquences relatives et les fréquences cumulées relatives peuvent être utilisées pour comparer deux ou plusieurs populations.
- Dans le cas d'une distribution continue, les données sont en général regroupées en classes. Les fréquences absolues, relatives et cumulées sont définies par rapport aux classes et non par rapport aux valeurs de la variable.

Variable continue Dans le cas où la variable X est continue, la réalisation d'un tableau de fréquence nécessite au préalable une répartition en classes des données. On doit définir *a priori* le nombre de classes K et l'amplitude (ou l'étendue) de chaque classe. Ce choix doit résulte d'un compromis entre deux objectifs antagonistes : résumer les données (K ne doit pas être trop grand) sans perdre l'information pertinente (K ne doit pas être trop petit). Pour ce faire, un moyen « simple » est de diviser l'étendue des données en plusieurs intervalles de même longueur, puis l'on regroupe les classes d'effectifs trop petit (ie moins de 5 individus). On peut utiliser une des deux règles suivantes pour déterminer le nombre de classes :

Règle de Sturge : $K = 1 + \frac{10}{3}\log_{10}(n)$

Règle de Yule : $K = 2.5n^{\frac{1}{4}}$

L'intervalle entre les classes est alors donné par

$$Longueur\ de\ l'intervalle = \frac{x_{max} - x_{min}}{K}$$

, où x_{max} (resp.x_{min}) désigne la plus grande (res. la plus petite) valeur de prise par les $X(\omega)$, $\omega \in \Omega$.
On note $\mathcal{C}_k$ l'ensemble des individus qui appartiennent à la classe K.
Le nombre de classes ne devrait être ni inférieur à 5, ni supérieur à 20 (il varie généralement entre 6 et 12). Ce choix est fonction du nombre d'observations et de leur dispersion .

Amplitude : L'amplitude L_k de la classe k est donnée par $L_k = \max\{X(\omega), \omega \in \mathcal{C}_k\} - \min\{X(\omega), \omega \in \mathcal{C}_k\}$ c'est-à-dire la longueur de l'intervalle. Si x_{k-1} et x_k sont les bornes respectivement inférieure et supérieure de la classe k alors

$$L_k = x_k - x_{k-1}$$

Densité : La densité d_k de la classe k est donnée par $d_k = \frac{n_k}{L_k}$

Ce découpage en classes permet de se ramener au cas discret décrit précédemment pour obtenir le tableau de fréquences, en adaptant directement les définitions vues précédemment.

Variable discrête : On complète le tableau de l'exemple des **défauts relevés sur une pièce de tissu** en calculant les fréquences relatives f_i , toutes les fréquences absolues cumulées N_i et les fréquences relatives cumulées F_i .

Nombre de défauts	n_i	f_i	N_i	F_i
0	38	0,506	38	0,506
1	15	0,20	$53 = 38 + 15$	0,706
2	11	0,146	$64 = 53 + 11$	0,853
3	6	0,08	$70 = 64 + 6$	0,933
4	3	0,04	$73 = 70 + 3$	0,973
5	2	0,026	$75 = 73 + 2$	1

Variable continue : Essais de fiabilité de dispositifs électroniques

100 dispositifs identiques ont été soumis à un test de fiabilité ; on a noté la durée de vie, en heures, jusqu'à défaillance (fin de l'aptitude du dispositif à remplir la fonction requise).

Durée de vie (en heures)	Nombre n_i de dispositifs (fréquence absolue)	Fréquence relative f_i	Fréquence cumulée absolue	Fréquence cumulée relative F_i
$0 \leqslant X < 150$	30	0,30	30	0,30
$150 \leqslant X < 300$	15	0,15	45	0,45
$300 \leqslant X < 450$	12	0,12	57	0,57
$450 \leqslant X < 600$	10	0,10	67	0,67
$600 \leqslant X < 750$	8	0,08	75	0,75
$750 \leqslant X < 900$	8	0,08	83	0,83
$900 \leqslant X < 1\,050$	8	0,08	91	0,91
$1\,050 \leqslant X < 1\,200$	6	0,06	97	0,97
$1\,200 \leqslant X < 1\,350$	3	0,03	100	1

Représentations graphiques

Lorsqu'on observe un caractère sur des individus, les tableaux de chiffres définis précédemment sont peu parlant. Ils sont cependant très utiles pour construire des graphiques divers, qui permettent d'un seul coup d'oeil d'avoir une idée de la manière dont se répartissent les individus.

Variables qualitatives On considère une variable statistique qualitative X prenant K modalités $x_1, \cdots, x_k, \cdots, x_K$. La seule représentation qui nous intéresse est celle des effectifs N_k ou des fréquences f_k. On utilise le tableau de fréquence pour construire les graphiques définis par la suite.

Diagramme en barre ou tuyaux d'orgue

- Les modalités de la variable sont placées sur une droite horizontale (**attention** : si la variable est nominale, ne pas orienter cette droite car les modalités n'ont pas de relation d'ordre).
- Les effectifs ou les fréquences sont placées sur un axe vertical. La hauteur du baton est proportionnelle à l'effectif.
- Les tuyaux ont une certaine épaisseur pour qu'il n'y ait pas de confusion avec les diagrammes en bâtons réservés à la variable quantitative discrète.
- Il doit y avoir un espace entre les tuyaux pour ne pas les confondres avec les histogrammes réservés aux variables quantitatives continues.

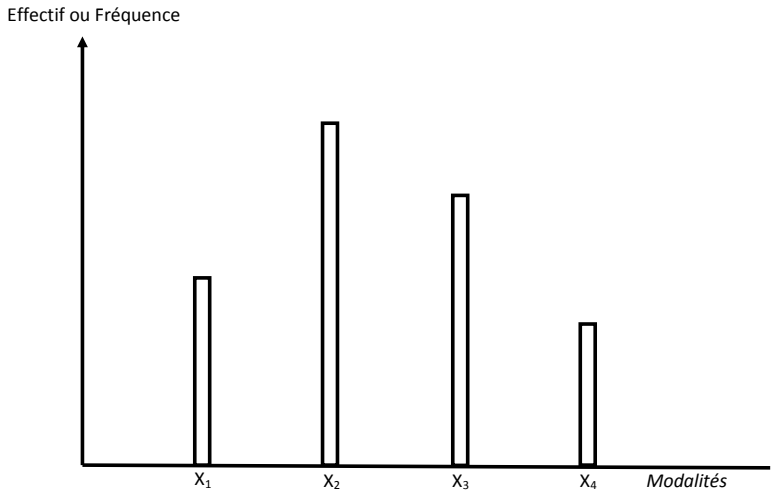


Figure – Diagramme en barres

Diagramme en secteurs ou « camenbert »

- L'effectif total est représenté par un disque.
- Chaque modalité est représentée par un secteur circulaire dont la surface (pratiquement : l'angle au centre) est proportionnelle à l'effectif correspondant.

Si ce type de graphique est couramment utilisé dans les médias, c'est une très mauvaise représentation car il présente un risque d'interprétation : l'oeil distingue moins bien les différences entre secteurs (d'un camembert) qu'entre hauteurs (d'un diagramme en barre).

Variables quantitatives

Avant toute tentative de représentation, il y a lieu de distinguer entre variable discrète et variable classée (regroupements en classes). Si pour une variable continue le regroupement en classes est nécessaire, lorsque les modalités d'une variable discrète sont trop nombreuses il est préférable de regrouper des modalités pour obtenir une variable classée, afin que les graphiques synthétisent l'information et restent lisibles.
On considère une variable statistique quantitatives X prenant ses valeurs parmis K modalités ou classes $x_1, \cdots, x_k, \cdots, x_K$. On suppose les modalités (ou classes) ordonnées telles que $x_1 < \cdots < x_k < \cdots < x_K$. On utilise le tableau de fréquence pour construire les graphiques définis par la suite. Deux types de graphiques sont intéressants à représenter :

(1) Les diagrammes différentiels qui mettent en évidence les différences d'effectifs (ou de fréquences) entre les différentes modalités ou classes.

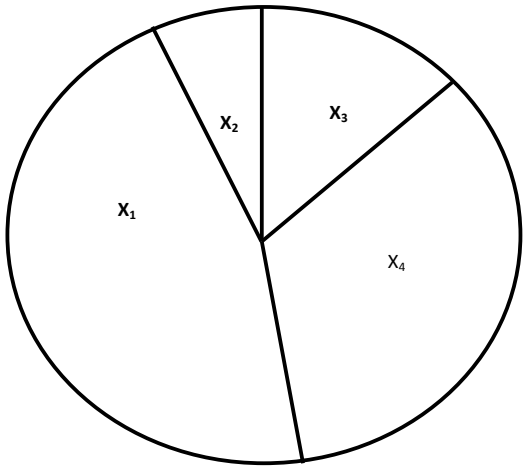


Figure – Diagramme en secteurs

Diagrammes différentiels :

Variables discrètes Pour les caractères quantitatifs discrets, la représentation graphique différentielle est le **diagramme en bâtons** où la hauteur des bâtons correspond à l'effectif N_k (ou la fréquence relative f_k) associé à chaque modalité du caractère x_k.

- Les valeurs discrètes prises par les modalités sont placées sur l'axe des abscisses, ordonnées comme il se doit.
- Les effectifs ou fréquences sont placées sur l'axe des ordonnées.
- Les axes sont fléchés.
- La hauteur du bâton est proportionnelle à l'effectif ou la fréquence.
- **Attention** : bien faire des batons et non des tuyaux ou des histogrammes.

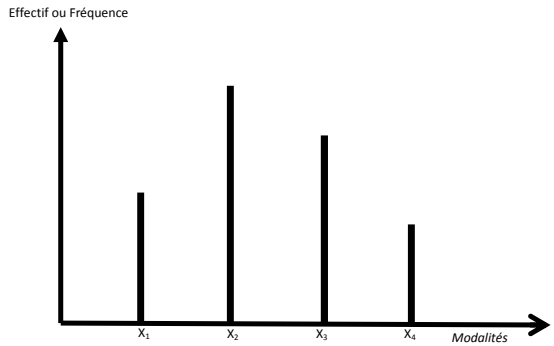


Figure – Diagramme en batons

Classement de 100 familles en fonction du nombre d'enfants : On a relevé le nombre d'enfants de 100 familles choisies au hasard. Le tableau ci-dessous donne les principales caractéristiques de cette étude.

x_i	0	1	2	3	4	5	6	7	Total
n_i	20	25	30	10	5	5	3	2	100
f_i	0,20	0,25	0,30	0,10	0,05	0,05	0,03	0,02	1
F_i	0,20	0,45	0,75	0,85	0,90	0,95	0,98	1	

x_i nombre d'enfants compris entre 0 et 7.
n_i nombre de familles ayant x_i enfants.
fi fréquence relative des familles ayant x_i enfants.
Fi fréquence cumulée des familles ayant au plus x_i enfants.

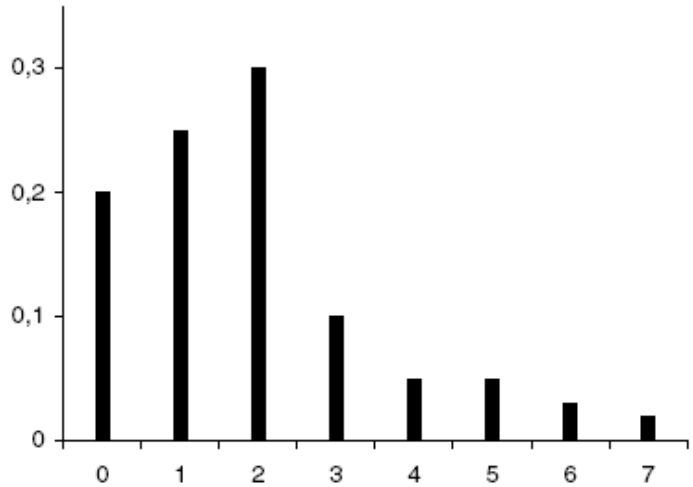


Figure – Diagramme en bâtons de la distribution de l'exemple de la famille

Variables continues. Lorsque les caractères quantitatifs sont continus, on utilise l'**histogramme**. Un histogramme est ensemble de rectangles contigus où chaque rectangle associé à chaque classe a une **surface** proportionnelle à l'effectif (fréquence) de cette classe. Si les classes sont d'amplitudes égales, alors la hauteur des rectangles est proportionnelle à l'effectif de la classes.**Avant toute construction d'histogramme, il faut donc regarder si les classes sont d'amplitudes égales ou non**.
Les modalités (continues) sont représentés en abscisses. Le cas des classes d'amplitudes égales ne pose aucune difficulté car il suffit de reporter en ordonnée l'effectif (la fréquence). Si les classes sont d'amplitudes différentes, on reporte en ordonnée la densité $d_k = \dfrac{n_k}{L_k}$.

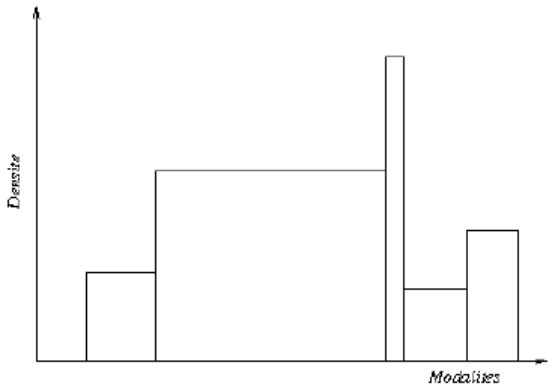


Figure – Histrogramme

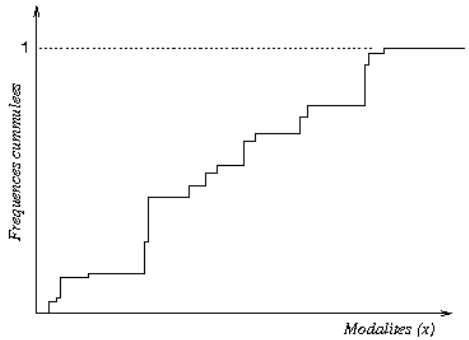
L'histogramme est un outil statistique facile à utiliser, donnant rapidement une image du comportement d'un procédé et l'allure globale de la distribution ; il montre l'étalement des données et apporte ainsi des renseignements sur la dispersion et sur les valeurs extrêmes ; il permet de déceler, éventuellement, des valeurs aberrantes.

diagrammes cummulatifs. Les diagrammes cummulatifs permettent de visualiser l'évolution des fréquences cummulées ou des effectifs cummulés. On utilise en général la **fonction de répartition empirique** dont la courbe correspond à l'évolution des fréquences cummulées. Elle se définie de la même manière pour les variables quantitatives continues ou discrètes.

Fonction de répartition empirique : Soit X une variable statistiques quantitative observée sur un échantillon $\omega_1, \cdots, \omega_n$ de taille n issue d'une population Ω. On appelle fonction de répartition empirique la fonction :

$$\widehat{F} = \begin{cases} 0, & x < x'_1 \\ F_i = \dfrac{1}{n}\displaystyle\sum_{j=1}^{i} n_j, & \text{si } x'_1 \leq x < x'_{i+1} \\ 1, & \text{si } x \geq x'_l \end{cases}$$

Pour tout réel x,$\widehat{F}$ est donc la proportion d'observations inférieurs ou égales à x. La fonction $\widehat{F}$ est une fonction en escalier. Le calcul pratique de $\widehat{F}$ s'effectue en ordonnant les n observations $X(\omega_1), \cdots, X(\omega_n)$ par ordre croissant. On note $x'_1, \cdots, x'_l$ les l valeurs distinctes obtenues et n_i l'effectif de x'_i.
On utilise la fonction de répartition empirique pour répondre aux questions du style : Quel est le nombre (ou le pourcentage) d'individus dont la valeur du caractère est inférieure ou égale à x ?



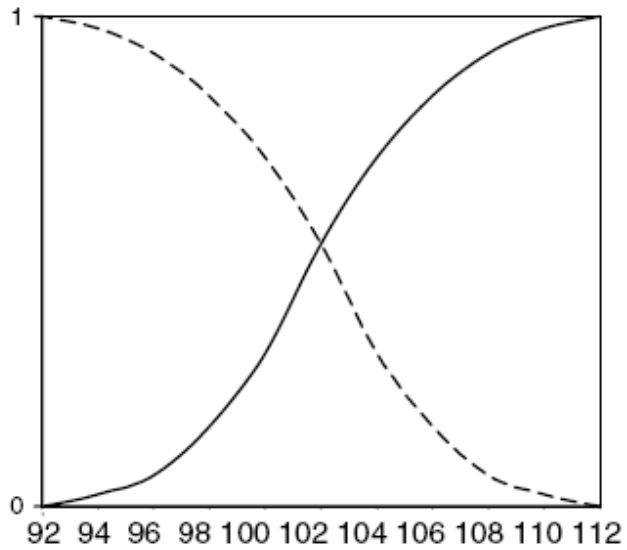
Polygone de fréquences

Il permet de représenter sous forme de courbe, la distribution des fréquences absolues ou relatives. Il est obtenu en joignant, par des segments de droite, les milieux des côtés supérieurs de chaque rectangle de l'histogramme. Pour fermer ce polygone, on ajoute à chaque extrémité une classe de fréquence nulle.

Étude de la dispersion d'un lot de 400 résistances : On a contrôlé 400 résistances dont la valeur nominale est égale à 100 $k\Omega$ et on a regroupé les résultats en classes d'amplitude 2 $k\Omega$qui représente environ le dixième de la dispersion totale de l'échantillon contrôlé.

Classe	Limites des classes	n_i	N_i	f_i	F_i
I	[92, 94[	10	10	0,025	0,025
II	[94, 96[	15	25	0,0375	0,0625
III	[96, 98[	40	65	0,10	0,1625
IV	[98, 100[	60	125	0,15	0,3125
V	[100, 102[	90	215	0,225	0,5375
VI	[102, 104[	70	285	0,175	0,7125
VII	[104, 106[	50	335	0,125	0,8375
VIII	[106, 108[	35	370	0,0875	0,925
IX	[108, 110[	20	390	0,05	0,975
X	[110, 112[	10	400	0,025	1

Les classes étant toutes de même amplitude, l'histogramme est facile à tracer ; il suffit de construire des rectangles dont l'aire est proportionnelle à la fréquence des résistances de la classe correspondante.



Courbes de fréquences cumulées

Courbe cumulative croissante : on joint les points ayant pour abscisses la limite supérieure des classes et pour ordonnées les fréquences cumulées croissantes correspondant à la classe considérée (pour le premier point, on porte la valeur 0). Elle donne le nombre d'observations inférieures à une valeur quelconque de la série.

Courbe cumulative décroissante : la construction de cette courbe est analogue à la précédente. Les points ont pour abscisses, les limites inférieures des classes et pour ordonnées, les fréquences cumulées décroissantes (pour le dernier point, la valeur est 0). Elle donne le nombre d'observations supérieures à une valeur quelconque de la série.

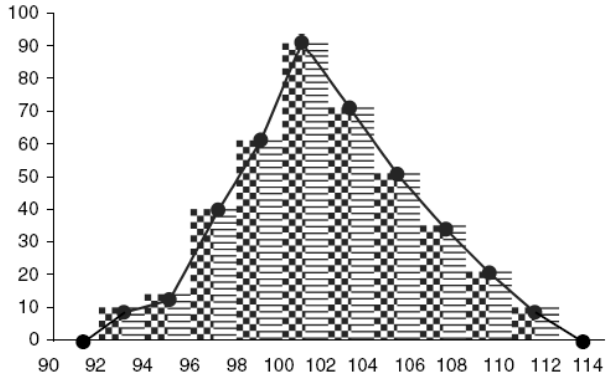


Figure – Histogramme de la distribution de l'exemple sur l'étude de dispersion

Mesures de tendance

On considère sur un échantillon de n individus la variable statistique $X = (X_1, X_2, \cdots, X_n)$
Indicateurs de tendance centrale : Les mesures de tendance centrale permettent de résumer un ensemble de données relatives à une variable quantitative. Elles permettent de déterminer une valeur « typique » ou centrale autour de laquelle des données ont tendance à se rassembler.
Moyennes : L'indicateur le plus couramment utilisé est la moyenne empirique ou moyenne arithmétique.

Moyenne arithmétique : On appelle **moyenne arithmétique** de X la quantité :

$$\overline{X} = \frac{X_1 + X_2 + \cdots + X_n}{n} = \frac{\sum_{i=1}^{n} X_i}{n}$$

Sur une série discrète la moyenne est : $\overline{X} = \frac{\sum_{i=1}^{k} n_i v_i}{n}$ où v_i est la modalité de la série et dans le cas de série continue classée $\overline{X} = \frac{\sum_{i=1}^{k} n_i c_i}{n}$ où c_i représente le centre de la classe i.

La moyenne possède, entre autre, la propriété importante suivante :

Proposition : La **somme** des écarts à la moyenne empirique est **nulle**.

En effet, $\sum_{i=1}^{n}(X_i - \overline{X}) = \sum_{i=1}^{n} X_i - n\overline{X} = 0$ L'inconvénient principal de la moyenne empirique comme indicateur de tendance centrale est d'être assez sensible à la présence de valeurs « abérantes ». Un indicateur de tendance centrale plus robuste est donné par la moyenne tronquée d'ordre k :

- La moyenne arithmétique permet de résumer par un seul nombre la série statistique.
- Elle prend en compte toutes les valeurs de la série et elle est facile à calculer.
- Elle est sensible aux valeurs extrêmes, il est parfois nécessaire de supprimer des valeurs extrêmes ou « aberrantes ».

Moyenne tronquée d'ordre k : On appelle moyenne tronquée d'ordre k de X la quantité

$$\overline{X}_k = \frac{1}{n-2k} \sum_{i=k+1}^{n-k} X_i$$

Cette moyenne s'obtient en fait en supprimant les k plus petites valeurs et les k plus grandes valeurs d'une observations.
Il existe d'autres moyennes, dont on donne la définition pour les plus courantes.

Définition : Moyenne géométrique : On appelle **moyenne géométrique** de X la quantité

$$M_g(X) = \sqrt[n]{X_1 X_2 \cdots X_n} = \sqrt[n]{\prod_{i=1}^{n} X_i}$$

L'utilisation de la moyenne géométrique fait sens si les valeurs ont un caractère multiplicatif.

Définition : Moyenne harmonique : On appelle **moyenne harmonique** de X la quantité

$$M_h(X) = \frac{n}{\frac{1}{X_1} + \frac{1}{X_2} + \cdots + \frac{1}{X_n}} = \frac{n}{\sum_{i=1}^{n} \frac{1}{X_i}}$$

On utilise la moyenne harmonique lorsqu'on veut déterminer un rapport moyen dans des domaines ou ils existent des liens de proportionnalité inverse.

Définition : Moyenne quadratique :On appelle **moyenne quadratique de X** la quantité

$$M_q(X) = \sqrt{\frac{1}{n} \sum_{i=1}^{n} X_i^2}$$

Définition : Généralisation de la moyenne : On peut généraliser la notion de moyenne de X de la façon suivante, pour $m \in \mathbb{R}$

$$M_m(X) = \sqrt[n]{\frac{1}{n} \sum_{i=1}^{n} X_i^m}$$

On retrouve les moyennes définies précédemment avec cette définition très générale :

Pour $m = 1$, $M_1(X)$ est la **moyenne arithmétique** ;

Pour $m = -1$, $M_{-1}(X)$ est la **moyenne harmonique** ;

Pour $m = 2$, $M_2(X)$ est la **moyenne quadratique** ;

Lorsque $m \to 0$ $M_m(X)$ tend vers la **moyenne géométrique**.

Théorème : Inégalité des moyennes : Soient $a \in \mathbb{R}$ et $b \in \mathbb{R}$. Soit une variable statistique X sur N individus. On note $M_0(X)$ la moyenne géométrique.

Si $a < b$ alors $M_a(X) < M_b(X)$

Quantiles

Les quantiles permettent de donner des indications du type « 1 personne sur 10 a moins de tel âge ».
La **médiane** est un indicateur de tendance centrale (plus robuste que la moyenne empirique) qui divise la population en deux parties, qui ont le même nombre d'individus. Autrement dit, elle sépare l'**échantillon en deux parties égales**.

Définition : Médiane : La médiane M_e est définie comme suit :

- Si n est impair alors $M_e = X_{\frac{n+1}{2}}$. la médiane est une valeur observée de la série
- Si n est pair alors $M_e = \dfrac{X_{n+1} + X_n}{2}$. on peut prendre pour valeur médiane, indifféremment l'une ou l'autre des valeurs centrales ou n'importe quelle valeur intermédiaire entre ces deux valeurs, par exemple, la moyenne arithmétique de ces deux valeurs, mais, dans ces conditions, ce n'est pas une valeur observée.

La formule de la médiane ci-dessous est valable pour les variables discrètes. Si les variables sont continues, la médiane M_e obtenue est dans l'intervalle $[x_{k-1}; x_k[$ avec la condition $F_{k-1} \leq 0.5 < F_k$ par l'interpolation linéaire : $M_e = x_{k-1} + (x_k - x_{k-1})\dfrac{0.5 - F_{k-1}}{F_k - F_{k-1}}$

Propriété :

- Le calcul de la médiane est rapide.
- La médiane n'est pas influencée par les valeurs extrêmes ou aberrantes.
- La médiane est influencée par le nombre des données mais non par leurs valeurs, elle ne peut donc pas être utilisée en théorie de l'estimation.
- Si la variable statistique est discrète, la médiane peut ne pas exister ; elle correspond seulement à une valeur possible de cette variable.
- La médiane est le point d'intersection des courbes cumulatives croissante et décroissante.
- La médiane ne se prête pas aux combinaisons algébriques ; la médiane d'une série globale ne peut pas être déduite des médianes des séries composantes.

Exemple : Dispersion d'un lot de 400 résistances ; Calcul de la moyenne arithmétique : $\overline{X} = 400\frac{1}{400}(93 * 10 * 1 + 95 * 15 + 97 * 40 + \cdots + 111 * 10) = 101,90$ La moyenne arithmétique est égale à 101,90 $k\Omega$. Médiane : la série des observations comporte un nombre pair de classes. On peut définir une classe médiane comme la moyenne des classes **V** et **VI**, c'est-à-dire la classe fictive $[101, 103[$ donc une résistance égale à 102 $k\Omega$. Un calcul plus précis consiste à chercher la valeur de la résistance de l'individu occupant le rang 200 (ou 200,5 !). Ne connaissant pas la distribution à l'intérieur des classes, on fait une interpolation linéaire. Le tableau de l'exemple **??** montre que cet individu appartient à la classe **V**.
125 résistances ont une valeur nominale inférieure à 100 $k\Omega$ et 215 résistances ont une valeur nominale inférieure à 102 $k\Omega$ d'où le calcul de la médiane : $100 + \frac{2 * (200 - 125)}{215 - 125} = 101,66.$
La médiane est égale à 101,66 $k\Omega$. Donc, 200 résistances ont une valeur nominale inférieure ou égale à 101,66 $k\Omega$ et 200 résistances ont une valeur nominale supérieure à 101, 66 $k\Omega$.
Le point d'intersection des deux courbes cumulatives a pour abscisse la médiane.

Exemple : On considère les séries d'observations suivantes. Série I : 5 observations classées par ordre croissant, 2, 5, 8, 11, 14
Moyenne arithmétique 8, médiane 8
Série II : 6 observations classées par ordre croissant, 6, 6, 14, 16, 18, 18
Moyenne arithmétique 13, médiane 15
Série III : les deux séries précédentes réunies, 2, 5, 6, 6, 8, 11, 14, 14, 16, 18, 18
Moyenne arithmétique 10,72, médiane 11
Plus généralement, on peut définir une valeur qui sépare l'échantillon en deux parties de tailles approximativement égale à αN, où $\alpha \in]a, b[$. Une telle valeur est appelée quantile ou fractile empirique d'ordre α. Plusieurs définitions existent, et l'on donne la suivante :

Définition : Quantile d'ordre α : Soit $\alpha \in]a, b[$ Si $\alpha n \in \ltimes$ alors $Q_\alpha = X_{\alpha n}$
Sinon $Q_\alpha = X_{\lfloor \alpha n \rfloor + 1}$

Les quantiles les plus utilisés sont les **quartiles** et les **déciles**. Les quartiles divisent les observations en **4 parties** $(Q_{25\%}, Q_{50\%}, Q_{75\%})$. Les déciles divisent l'ensemble des observations en **10 parties** : $(Q_{10\%}, Q_{20\%}, Q_{30\%}, Q_{40\%}, Q_{50\%}, Q_{60\%} \cdots)$
Enfin, un indicateur de position souvent utilisé dans le cas d'un caractère discret est le **mode**, défini comme la valeur la plus fréquente dans la série d'observation (cette valeur n'est pas nécessairement unique). Dans le cas d'un caractère continu, cette notion ne s'applique pas directement, mais on peut définir une **classe modale**, lorsque les données ont été préalablement catégorisées.
Les mesures données ci-dessus possèdent les deux propriétés suivantes, qui permettent de savoir comment les données se comportent si elles subissent une translation ou un changement d'échelle. Intuitivement, le « centre » d'une distribution doit « suivre »la transformation car celle-ci ne pertube pas la position relative des points observés.

Application : boîte à moustaches

Le diagramme en boîte à moustaches ou *box-plot* (*Tukey*)ou b**ox-andWiskers plot** permet de représenter schématiquement les principales caractéristiques d'une distribution en utilisant les quartiles.

La partie centrale de la distribution est représentée par une boîte de largeur arbitraire et de longueur la distance interquartile, la médiane est tracée à l'intérieur.

La boîte à moustache résume la série à partir de ses valeurs extrêmes, ses quartiles et sa médiane. Elle permet une comparaison visuelle immédiate de plusieurs séries. La boîte rectangle est complétée par des moustaches correspondant aux valeurs suivantes :

- valeur supérieure : $Q_3 + 1,5(Q_3 - Q_1)$
- valeur inférieure : $Q_1 - 1,5(Q_3 - Q_1)$

Les valeurs extérieures « aux moustaches »sont représentées par des étoiles ou des petits cercles et peuvent être considérées comme aberrantes.

$I = Q_3 - Q_1$ est appelé l'**intervalle inter-quartile** et comporte 50% des observations de la série.

On trace un rectangle de longueur l'inter-quartile et la largeur proportionnelle à la racine carrée de la taille de la série.

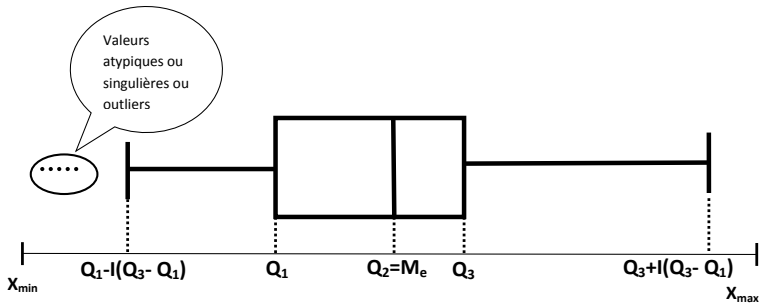


Figure – Exemple de boîte à moustaches (les astérisques $*$ représentent les valeurs aberrantes de la distribution)

Proposition : Translation : Soit $a \in \mathbb{R}$ et la variable statistique Y définie comme $Y = X + a$. Alors on a $\mu_Y = \mu_X + a$, où μ désigne une mesure de tendance centrale (par exemple, la moyenne ou la médiane).

Proposition : Changement d'échelle : Soit $a \in \mathbb{R}$ et la variable statistique Y définie comme $Y = aX$. Alors on a $\mu_Y = a\mu_X$, où μ désigne une mesure de tendance centrale (par exemple, la moyenne ou la médiane).

Enfin, on peut se demander quels **relations** il existent entre la **moyenne** et la **médiane**. De manière générale, il n'existe pas de lien entre la moyenne et la médiane. Cependant, on comparera souvent la moyenne et la médiane pour **caractériser la distribution d'une série statistique** :

- ♣ Si la **moyenne est supérieure à la médiane**, on dit que la distribution des valeurs observées présente **une dissymétrie positive**.
- ♣ Si la **moyenne est inférieure à la médiane**, on dit que la distribution des valeurs observées présente une **dissymétrie négative**.
- ♣ Si la **moyenne est égale à la médiane**, on dit que la **distribution des valeurs observées est symétrique**.

Mode : Définition : Le mode est une moyenne de fréquence.

Le mode : Le mode est la valeur de la variable statistique la plus fréquente que l'on observe dans une série d'observations.

Si la variable est une variable discrète, le mode s'obtient facilement. Si la variable est une variable continue, on définit une classe modale.

Propriété :

- Le mode n'existe pas toujours et quand il existe, il n'est pas toujours unique.
- Si après regroupement des données en classes, on trouve deux ou plusieurs modes différents, on doit considérer que l'on est en présence de deux ou plusieurs populations distinctes ayant chacune leurs caractéristiques propres ; dans ce cas, la moyenne arithmétique n'est pas une caractéristique de tendance centrale.

Exemple : **Dispersion d'un lot de 400 résistances** : On ne peut pas définir une valeur modale en ne connaissant pas la distribution à l'intérieur de chaque classe. On définit une classe modale, c'est la classe **V**.
Exemple : Avec l'exemple sur les séries d'observation. Série I : pas de mode.
Série II : deux modes 6 et 18.
Série III : les deux séries réunies, trois modes 6, 14 et 18.
Remarque : Pour définir n'importe quelle caractéristique (excepté la moyenne arithmétique), il faut que les données soient classées en ordre croissant (ou décroissant). Pour le calcul de la médiane, on peut trouver un résultat différent selon que les données sont classées par ordre croissant ou décroissant.

Indicateurs de dispersion

Comme le nom l'indique, les indicateurs de dispertions permettent de mesurer comment les données se « répartissent ». On peut définir deux types de mesure de dispersions :

- ♠ Les mesures définies par la distance entre deux valeurs représentatives de la distribution
- ♠ Les mesures calculées en fonction de la déviation par rapport à une valeur centrale

Définition : Étendue : L'étendu d'une série statistique est l'écart entre sa plus grande valeur et sa plus petite.

$$e = \max X - \min X$$

Ce dernier indicateur est très peu robuste. On lui préférera souvent l'intervalle inter-quartile.
Un premier moyen de mesurer la dispersion des données autour de la moyenne est l'écart moyen absolu.

Propriété :

- L'étendue est facile à calculer.
- Elle ne tient compte que des valeurs extrêmes de la série ; elle ne dépend ni du nombre, ni des valeurs intermédiaires ; elle est très peu utilisée dès que le nombre de données dépasse 10.
- Elle est utilisée en contrôle industriel où le nombre de pièces prélevées dépasse rarement 4 ou 5 ; elle donne une idée appréciable de la dispersion. Cependant, dès que cela est possible, on préfère prélever 15 à 20 unités et utiliser l'écart-type pour apprécier la dispersion.

Écart moyen absolu

Définition : Écart moyen absolu : L'écart moyen absolu est définie par la quantité

$$\frac{1}{n}\sum_{i=1}^{n}|X_i - \overline{X}|$$

Cette mesure à l'inconvénient mathématique de ne pas être dérivable partour (la valeur absolue n'est pas dérivable en 0). On corrige ce problème en mesurant la moyenne des écarts élevés au carré. On obtient alors la définition de la variance empirique :

Variance empirique

Définition : Variance empirique : On appelle **variance empirique** de la série statistique X la quantité

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

Un **moyen pratique de calculer la variance empirique** est donné par la proposition suivante :
Proposition :

On appelle variance empirique de la série statistique X la quantité

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}X_i^2 - \overline{X}^2$$

Proposition : **à démontrer**
Cet estimateur pose un autre problème : il est **biaisé**. On utilise alors en pratique une version corrigée

Variance empirique corrigée et Écart-type

Définition : Variance empirique corrigée :

$$\sigma^{*2} = \frac{1}{n-1}\sum_{i=1}^{n} X_i^2 - \overline{X}^2$$

Proposition :

$$\sigma^{*2} = \frac{n}{n-1}\sigma^2$$

Enfin, pour avoir une quantité qui s'exprime dans la même unité que la moyenne (l'unité de la variance est l'unité de la moyenne élevée au carré), on utilise l'écart-type.

Définition : Écart-type : On définit l'**écart type empirique** comme la racine de la variance empirique :

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2}$$

Les mesures de dispertions possèdent notamment les propriétés suivantes :

Proposition (Invariance par translation) Les quantités de mesure de dispertion définies ci-dessus sont invariantes par translation.

Proposition (Changement d'échelle) Soit $a \in \mathbb{R}$ et $Y = aX$. On note σ_Y^2 (resp.σ_X^2) la variance de Y (resp. de X). On a $\sigma_Y^2 = a^2\sigma_X^2$ et $\sigma_Y = a\sigma_X$

Propriété

- L'écart-type caractérise la dispersion d'une série de valeurs. Plus σ est petit, plus les données sont regroupées autour de la moyenne arithmétique $\overline{X}$ et plus la population est homogène ; cependant avant de conclure, il faut faire attention à l'ordre de grandeur des données.
- L'écart-type permet de trouver le pourcentage de la population appartenant à un intervalle centré sur l'espérance mathématique.
- La variance tient compte de toutes les données, c'est la meilleure caractéristique de dispersion (nombreuses applications en statistique).

Exemple : Séries d'observations de l'exemple précédent :
Série I
Variance : 18
Écart-type : 4,24
Série II
Variance : 26,33
Écart-type : 5,13
Série III (les deux séries réunies)
Variance : 28,75
Écart-type : 5,36

Pour une série discrète la variance est : $\sigma^2 = \frac{1}{n}\sum_{i=1}^{n} n_i(v_i - \overline{X})^2$ où v_i représente la modalité de la variable discrète et dans le cas d'une variable continue (intervalle) on a $\sigma^2 = \frac{1}{n}\sum_{i=1}^{n} n_i(c_i - \overline{X})^2$ avec c_i est le centre de la classe i.

Coefficient de variation

Définition : Coefficient de variation : Il s'exprime, sous la forme d'un pourcentage, par l'expression suivante :

$$CV = \frac{\sigma}{\overline{X}} * 100$$

.

Propriété :

- Le coefficient de variation ne dépend pas des unités choisies.
- Il permet d'apprécier la représentativité de la moyenne arithmétique $\overline{X}$ par rapport à l'ensemble des données.
- Il permet d'apprécier l'homogénéité de la distribution, une valeur du coefficient de variation inférieure à 15 % traduit une bonne homogénéité de la distribution.
- Il permet de comparer deux distributions, même si les données ne sont pas exprimées avec la même unité ou si les moyennes arithmétiques des deux séries sont très différentes.
- Quelques exemples de coefficient de variation : le coefficient de variation du régime nival est voisin de 0,1 ; celui d'un cours d'eau régulier de 0,3 mais il peut atteindre 0,5 et même 1 pour un cours d'eau irrégulier.

Indicateurs de forme

Les indicateurs de forme donnent une idée de la symétrie et de l'aplatissement d'une distribution. Leur usage est moins fréquent.

Distribution symétrique Une série a une distribution symétrique si ses valeurs sont également dispersées de part et d'autre de la valeur centrale, c'est-à-dire si le graphe de la distribution - histogramme ou diagramme en bâton en fréquences - admet une axe de symétrie.

Dans une distribution parfaitement symétrique, $M_e = \overline{X} = Mode$ **Coefficient d'asymétrie de Pearson :**

$$\delta = \frac{\overline{X} - M_e}{\sigma}$$

. On a $-1 \leq \delta \leq 1$.

- Si $\delta = 0$ alors la symétrie parfaite.
- Si $\delta < 0$ alors la série étalée à gauche.
- Si $\delta > 0$ alors la série étalée à droite.

Coefficient de Yule

$$q = \frac{Q_3 + Q_1 - 2M_e}{Q_3 - Q_1}$$

- Si $q = 0$ alors la symétrie parfaite.
- Si $q < 0$ alors la série étalée à gauche.
- Si $q > 0$ alors la série étalée à droite.

Applatissement : Une distribution est plus ou moins aplatie selon que les fréquences des valeurs voisines des valeurs centrales diffèrent peu ou beaucoup les une par rapport aux autres.

coefficient d'aplatissement de Fisher ou kurtosis : $a = \frac{m_4}{\sigma^4}$ avec

$$m_4 = \sum_{i}^{n} (x_i - \overline{X})^4$$

- Si $a = 3$ pour une distribution qui suit une loi normale centrée réduite.
- Si $a < 3$ la concentration des valeurs de la série autour de la moyenne est forte : la distribution n'est pas aplatie.
- Si $a > 3$ la concentration des valeurs autour de la moyenne est faible : la distribution est aplatie.

Indicateurs de concentration

Ces caractéristiques sont utilisées pour une grandeur positive cumulative telle que le revenu, la consommation ...
La concentration est définie pour les variables statistiques positives en utilisant la notion de valeurs globales.
On appelle la **valeur globale totale** :

$G = \sum_{j=1}^{r} x_j$ pour un caractère discret et des observations non groupées.

$G = \sum_{j=1}^{r} n_j x_j$ pour un caractère discret et des observations groupées. pour un caractère continu, x_i est remplacé par le centre de classe c_i .
La **valeur globale absolue partielle** g_i de la modalité i s'exprime par : $g_i = n_i x_i$ pour un caractère discret et $g_i = n_i c_i$ pour un caractère continu.

La valeur globale absolue cumulée $G_i = \sum_{j=1}^{i} g_j$.

La valeur globale relative partielle $q_i = \frac{g_i}{G}$.

La valeur globale relative cumulée $Q_i = \sum_{j=1}^{r} q_j = \frac{G_i}{G}$ où r est le nombre de classe.

L'indice de Gini est :

$$i_g = 1 - [F_1 Q_1 + \sum_{i=2}^{r}(F_i - F_{i-1})(Q_i + Q_{i-1})] = 1 - [f_1 Q_1 + \sum_{i=2}^{r} f_i(Q_i + Q_{i-1})]$$

Plus la distribution de X est inégalement répartie, plus la courbe de concentration s'éloigne de la première bissectrice, la première bissectrice traduisant l'équirépartition. La courbe en rouge de la figure est appelée la **courbe de Lorentz**.

En pratique, lorsqu'on s'intéresse à la répartition d'une masse au sein d'une population, on trace d'abord une courbe de LORENZ afin d'avoir une idée visuelle de l'égalité ou de l'inégalité de cette répartition. Ensuite, si l'on désire résumer cette inégalité par un chiffre, on calcule le coefficient de GINI.

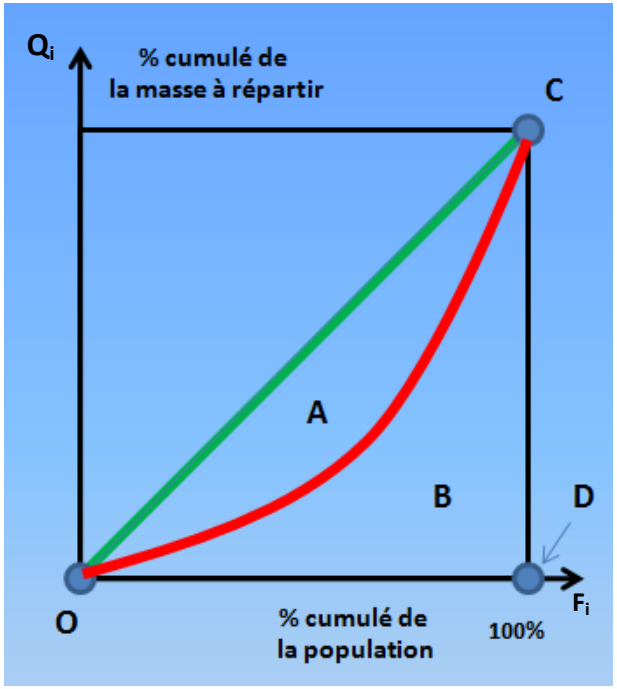


Figure – Courbe de concentration et indice de Gini

Liaison entre deux variables statistiques

On dispose de deux séries x et y représentant l'observation des variables X et Y sur les mêmes n individus : on a une série bidimensionnelle (x, y) de taille n. Nous voulons mettre en évidence une éventuelle variation simultanée des deux variables statistiques X et Y, appelée **liaison**.
La liaison peut être

- **causale** : une variable X expliquant l'autre Y.
- **symétrique** : les deux variables jouent des rôles symétriques.

Sauf mention particulière, on s'intéresse ici à une liaison symétrique. **Visualisation :**

Le graphique le plus adapté pour observer les variations simultanées de deux variables quantitatives est le nuage de points (ou scatter-plot), représentant les n points de coordonnées (x_i, y_i)dans un repère du plan.

Indicateurs de liaison linéaire

Définition : La covariance : de la population respectivement de la population est définie par :

$$cov(x, y) = \rho(x, y) = \rho_{xy} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y}) \text{ et}$$

$$cov^*(x, y) = \rho^*(x, y) = \rho^*_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})$$

Propriété :

- c' est une forme bilinéaire symétrique qui peut prendre toute valeur réelle et dont la variance est la forme quadratique associée. On a (idem pour $cov^*(x, y)$).
  $\rho(ax + by, z) = a\rho(x, z) + b\rho(y, z)$; $\rho(x, ay + bz) = a\rho(x, y) + b\rho(x, z)$;
  $\rho(x, y) = \rho(y, x)$; $\rho(x, x) = \sigma^2$.
- formule de Koenig généralisée : $\rho(x, y) = \frac{n-1}{n}\rho(x, y)^* = \overline{xy} - \overline{xy}$

Lorsque le nuage de points est allongé suivant une direction de droite, on a affaire à une corrélation linéaire entre x et y. L'intensité de la dépendance est alors mesurée par le coefficient de corrélation linéaire.

Définition : Le coefficient de corrélation linéaire de Pearson : le coefficient de corrélation est égal à la covariance des séries centrées et réduites x^* et y^* respectivement associées à x et y :

$$r(x, y) = \rho(x^*, y^*) \text{ avec } x^* = \frac{x_i - \overline{x}}{\sigma_x}) \text{ et } y^* = \frac{y_i - \overline{y}}{\sigma_y}).$$

Le coefficient de corrélation est égal à : $r(x, y) = \frac{\rho(x,y)}{\sigma_x \sigma_y}$

Propriété :

- Symétrie : $r(x, y) = r(y, x)$.
- Le coefficient de corrélation linéaire est compris entre -1 et 1.

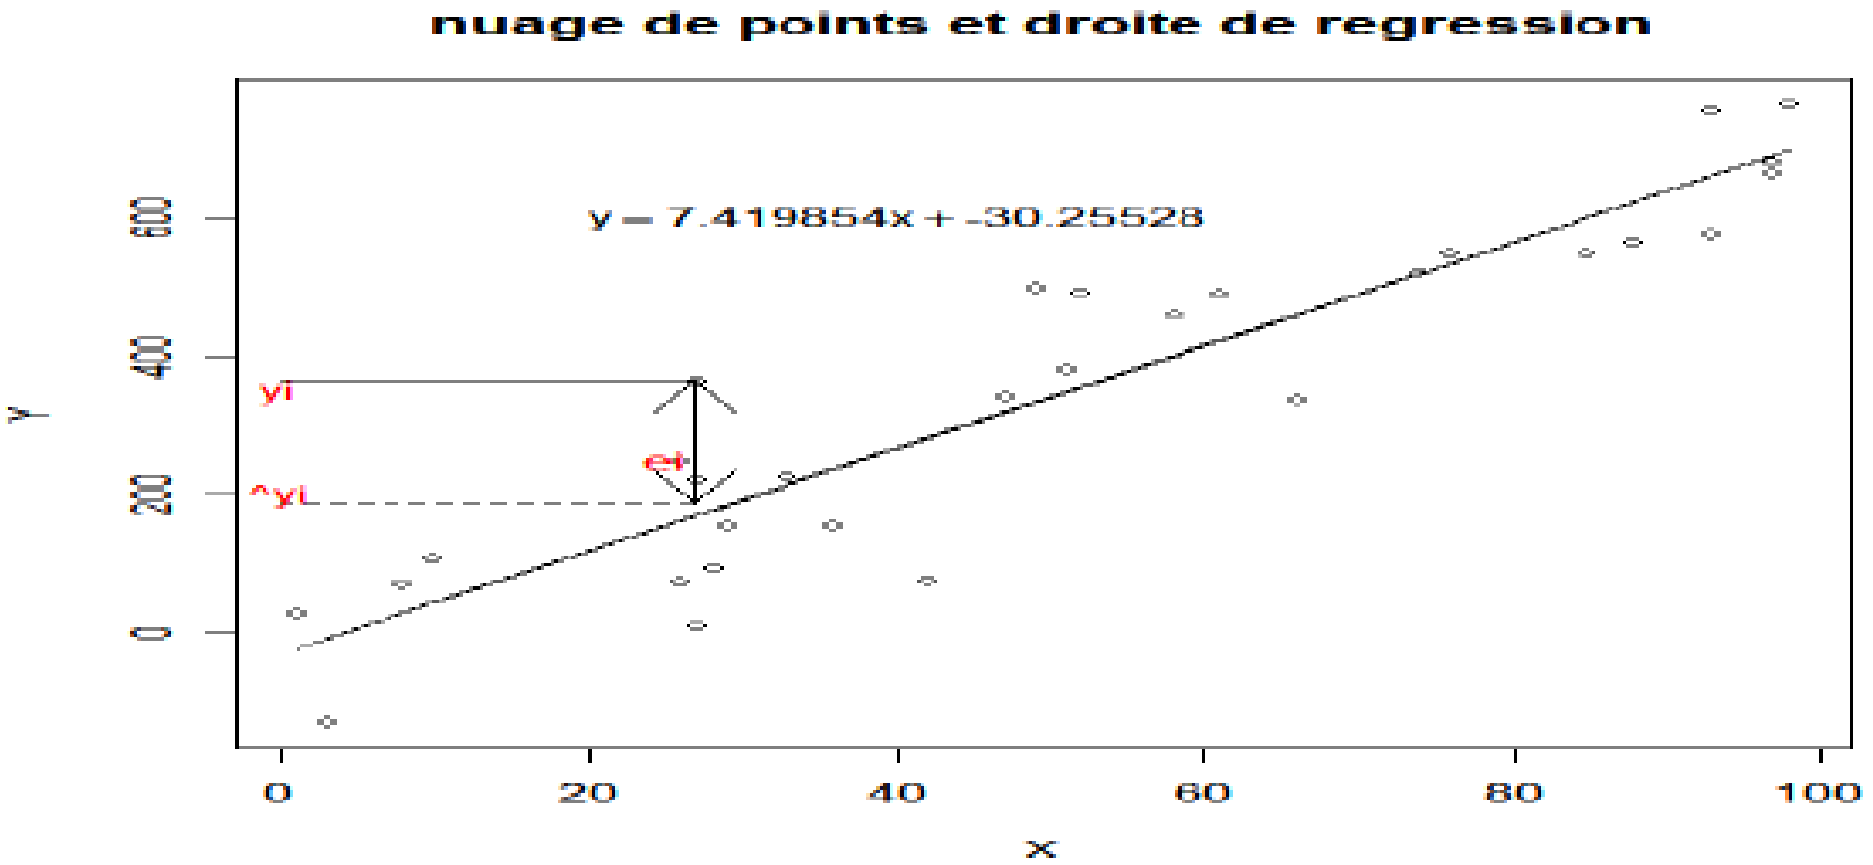
Evaluation du lien linéaire entre 2 variables quantitatives Il y a corrélation positive lorsque les variations de x et y se produisent dans le même sens, corrélation négative sinon. Plus les points sont étroitement alignés, plus la corrélation est proche de 1.

- $\mid r \mid = 1$ si l'on a une relation de type linéaire entre les variables.
- $r = 0$ si il n'existe aucun lien linéaire entre X et Y. On dit que les variables sont non corrélées.

La covariance dépend des unités de mesure dans lesquelles sont exprimées x et y. Le coefficient de corrélation est un indice de liaison « intrinsèque ».
La covariance et le coefficient de corrélation ne permettent de mettre en évidence qu'une relation linéaire entre x et y.
Si deux variables sont statistiquement indépendantes (aucun lien), la corrélation est nulle, mais l'inverse est faux : il peut exister un lien autre que linéaire entre elles.
Choix des échelles : Dans le cas de deux variables homogènes (exprimées dans la même unité), on prend la même échelle sur les deux axes ; dans le cas de deux variables hétérogènes, il est préférable de représenter les points de la série **centrée et réduite** ou de choisir des échelles appropriées (automatique avec la plupart des logiciels).

Définition : La régression linéaire : Lorsqu'il y a liaison fonctionnelle entre x et y on dit qu'il y a **régression** de y en x ou y est expliquée par x si $y = f(x)$. La courbes représentative de $f(x)$ est appelée courbe de régression. Il y a régression linéaire lorsque la courbe de régression est une droite si et seulement si $\mid r \mid = 1$. Lorsque $r \simeq 1$, le nuage de points est distribué autour d'une droite. On admet alors qu'approximativement $y \simeq f(x)$, et que les différences constatées sont dues aux fluctuations d'échantillon et diverses erreurs d'observation qui surviennent de manière aléatoire.
Il existe alors deux réels a et b tels que $y \simeq ax + b$. $Y = aX + b$ est l'équation de la droite de régression de y en x .

Calcul des coefficients de la droite de régression :
On commence par chercher le "meilleur" ajustement linéaire sur nos données, au sens des moindres carrés :



$\widehat{a}$ et $\widehat{b}$ sont tels que $\sum_{i=1}^{n} e_i^2 = S(\widehat{a}, \widehat{b}) = (y_i - \widehat{a}x - \widehat{b})^2$ est minimal. Ce sont les coefficients de la régression ou estimations des moindres carrésde a et b. $S(\widehat{a}, \widehat{b})$ sera minimum lorsque $\frac{\partial S}{\partial \widehat{a}} = \frac{\partial S}{\partial \widehat{b}} = 0$.

Après résolution on obtient : $\widehat{a} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sum_{i=1}^{n}(x_i - \overline{x})^2} = \frac{cov(x,y)}{\rho_x^2}$ et $\widehat{b} = \overline{y} - \widehat{a}\overline{x}$.

- La droite d'ajustement $y = \widehat{a}\overline{x} + \widehat{b}$ s'appelle droite de régression ou des moindres carrés.
- La valeur $y_i = \widehat{a}\overline{x_i} + \widehat{b}$ s'appelle la $i^{ème}$ valeur estimée. C'est la valeur moyenne de Y lorsque $X = x_i$. C'est aussi la prévision de Y pour une observation telle que $X = x_i$.
- La valeur $e_i = y_i - \widehat{y_i}$ s'appelle le $i^{ème}$ résidu. On peut montrer que : $\sum_{i=1}^{n} e_i = 0$

liaison entre 2 variables qualitatives : On suppose que les deux variables étudiées sont des variables discrètes et que les caractères sont des caractères quantitatifs. Les tableaux statistiques portent le nom de tableaux croisés ou tableaux de contingence.
Dans chaque case du tableau, on écrit l'effectif n_{ij} de l'échantillon, c'est-à-dire le nombre de données tel que $X = x_i$ et $Y = y_j$. On définit les fréquences absolues suivantes :

- Les **fréquences marginales** : $n_{i\bullet} = \sum_{j=1}^{q} n_{ij}$ et $n_{\bullet j} = \sum_{i=1}^{p} n_{ij}$
- La **fréquence marginale** $n_{i\bullet}$. est donc le nombre d'individus possédant la modalité i du caractère X quelle que soit la distribution du caractère Y ; par exemple tous les individus ayant le même poids quelle que soit leur taille.
- Les **fréquences conditionnelles** sont définies pour chaque valeur de i et j.
- La **fréquence conditionnelle** $n_{j/i}$ est la distribution de la variable Y quand on a fixé la modalité i pour la variable X ; on s'intéresse, par exemple, à la répartition des tailles des individus ayant tous le même poids. Elle est définie par : $n_{j/i} = \dfrac{n_{ij}}{n_{i\bullet}}$
- On définit de la même façon la fréquence conditionnelle $n_{j/i}$ par : $n_{j/i} = \dfrac{n_{ij}}{n_{\bullet j}}$.

  On s'intéresse, par exemple, à la répartition des poids des individus ayant tous la même taille.
- Les **fréquences relatives** f_{ij} , $f_{i\bullet}$ et $f_{\bullet j}$ sont obtenues en divisant les effectifs n_{ij} et les fréquences marginales $n_{i\bullet}$ et $n_{\bullet j}$ par l'effectif total n.
- Les distributions X et Y sont statistiquement indépendantes si et seulement si : $f_{ij} = f_{i\bullet} f_{\bullet j}$ pour toutes les valeurs des indices i et j.

Définition : Le coefficient de Khi-deux : la mesure de la liaison entre X et Y va se faire en évaluant l'écart entre la situation observée et la situation qu'on observerait si il y avait indépendance statistique. Cet écart appelé coefficient de Khi-deux est :

$$\chi^2 = \sum_{i=1}^{p}\sum_{j=1}^{q} \frac{(n_{ij} - \frac{n_{i\bullet}n_{\bullet j}}{n})^2}{\frac{n_{i\bullet}n_{\bullet j}}{n}}.$$

Plus χ^2 est petit, plus la liaison entre les variables X et Y est forte.

Le χ^2 n'étant pas borné, il est difficile d'apprécier l'importance de la dépendance ou de comparer deux distributions. Il est donc important de quantifier ce lien si elle existe entre les deux variables qualitatives. Nous donnons ici trois varaintes de coefficient :

- **Coefficient de contingence** : $\sqrt{\frac{\chi^2}{\chi^2 + n}}$
- **Coefficient de Pearson** : $\Phi^2 = \frac{\chi^2}{n}$
- **Coefficient de Tschuprow** : $T = \frac{\Phi^2}{\sqrt{(p-1)(q-1)}}$ où p et q désignent le nombre de modalités prises par les variables X et Y respectivement. Ce coefficient est analogue à un coefficient de corrélation linéaire $0 < T < 1$

Échantillonnage et estimation

Tests d'hypothèses

Application avec le logiciel R

Bibliographie

- Kowalski M. (2009), Tableaux statistiques et graphiques, http://webpages.lss.supelec.fr/perso/kowalski/downloads/Enseignement/2008_2009/StatDes/cours2.pdf, consulté le 29/08/2013
- Kowalski M.(2009), Mesures de tendance centrale et de dispersion, http://webpages.lss.supelec.fr/perso/kowalski/downloads/Enseignement/2008_2009/StatDes/cours3.pdf, consulté le 29/08/2013
- Veysseyre R. (2006), Aide-méoire statistique et probabilités pour l'ingénieur, 2ème édition 448 pages
- Traoré E., Cours de statistique et probabilités EIER-ETSHER, pour Bachelor 3, 46 pages.
- Anderson J.P.(2008), probabilités et statistique en S5 IFIPS, 107 pages. http://www.math.u-psud.fr/~pansu/web_ifips/proba_S5-IFIPS.pdf
- Mouchiroud D., Cours de probabilités et statistique du premier cycle universitaire pour biologiste. http://spiral.univ-lyon1.fr/mathsv/